

Curso de Fundamentos a Estadística y Probabilidad

**Ilse Beatriz Zubieta Martínez
@werlix**

¿Quién es Ilse?

-  **Matemática aplicada.**
-  **Data Analyst desde 2017.**
-  **Mexicana.**
-  **Cantante de clóset.**

Requisitos previos

- **+ Aritmética básica.**
- **✕ Álgebra básica.**
-  **Microsoft Excel o Google Sheets.**
-  **Muchas ganas de terminar este curso. :)**

Estadística: ¿Qué es y por qué aprenderla?



“

La estadística es la ciencia de la interpretación de los datos.

”



¿Qué es estadística?

**¿Qué
interpretas
aquí?**







Reto

Cuéntame, ¿por qué te uniste a este curso?

Quiero leer tus objetivos y en cuál área te gustaría aplicar los conocimientos que adquiriremos. 💪 😊

Conceptos clave

¿Qué es la estadística
y con qué se come?

Definiciones básicas

Tania, 160;
Damián, 188;
Michelle, 162;
Gilberto, 169;
Laura, 172

Tania, 160;
Damián, 188;
Michelle, 162;
Gilberto, 169;
Laura, 172

Nombre	Altura (m)
Tania	1.60
Damián	1.88
Michelle	1.62
Gilberto	1.69
Laura	1.72

Tania, 160;
Damián, 188;
Michelle, 162;
Gilberto, 169;
Laura, 172

Individuos

Variables

Variables	
Nombre	Altura (m)
Tania	1.60
Damián	1.88
Michelle	1.62
Gilberto	1.69
Laura	1.72

Tipo	Cantidad	Color	¿Tiene rueditas?
Samsonite	30	Negro	Sí
Samsung	45	Gris	No
OE	28	Marrón	No
Chloe	31	Negro	No
Gorett	17	Negro	Sí
Barbie	9	Rosa	No


1 Cuantitativa

6
Individuos


Tipo	Cantidad	Color	¿Tiene rueditas?
Samsonite	30	Negro	Sí
Samsung	45	Gris	No
OE	28	Marrón	No
Chloe	31	Negro	No
Gorett	17	Negro	Sí
Barbie	9	Rosa	No

2 Cualitativas

Variables




- **Categóricas**
 - Ordinal
 - Nominal



- **Numéricas**
 - Discretas
 - Continuas

Niveles de medida



Nominal



Ordinal



De intervalo



De proporción

19 Variables

2 Individuos	Precio en miles de dólares	Tamaño en m²	Precio por m²	Baños	Habitaciones	Bodega	Rooftop	Año construido	Predial	Pago mensual	Dirección	Cantidad de dueños	Piso	Altura m	Material de Piso	Llave automática	Cuarto de lavado	Tipo de gas	Servicios incluidos
Orquídea	300000	110	2728	3	3	Sí	Propio	1972	5%	1500	Calle 1, esq. Calle 34	1	300%	2.3	Madera	Sí	Sí	Natural	No
Geranio	150000	75	2000	1	2	No	Compartido	2010	2%	750	Avenida de los Monjes 236	7	PB	2.7	Azulejo	Sí	Compartido	Estacionario	No

	Orquídea	Geranio
Precio en miles de dólares	300000	150000
Tamaño en m²	110	75
Precio por m²	2728	2000
Baños	3	1
Habitaciones	3	2
Bodega	Sí	No
Rooftop	Propio	Compartido
Año construido	1972	2010
Predial	5%	2%
Pago mensual	1500	750
Dirección	Calle 1, esq. Calle 34	Avenida de los Monjes 236
Cantidad de dueños	1	7
Piso	3	PB
Altura m	2.3	2.7
Material de Piso	Madera	Azulejo
Llave automática	Sí	Sí
Cuarto de lavado	Sí	Compartido
Tipo de gas	Natural	Estacionario
Servicios incluidos	No	No

Tipo de Variable	Variables	Orquídea	Geranio
Cuantitativa	Precio en miles de dólares	300000	150000
Cuantitativa	Tamaño en m²	110	75
Cuantitativa	Precio por m²	2728	2000
Cuantitativa	Baños	3	1
Cuantitativa	Habitaciones	3	2
Cualitativa	Bodega	Sí	No
Cualitativa	Rooftop	Propio	Compartido
Cuantitativa	Año construido	1972	2010
Cuantitativa	Predial	5%	2%
Cuantitativa	Pago mensual	1500	750
Cualitativa	Dirección	Calle 1, esq. Calle 34	Avenida de los Monjes 236
Cuantitativa	Cantidad de dueños	1	7
Cualitativa	Piso	3	PB
Cuantitativa	Altura m	2.3	2.7
Cualitativa	Material de Piso	Madera	Azulejo
Cualitativa	Llave automática	Sí	Sí
Cualitativa	Cuarto de lavado	Sí	Compartido
Cualitativa	Tipo de gas	Natural	Estacionario
Cualitativa	Servicios incluidos	No	No

Tipos de estadística

Estadística descriptiva


Recopila, organiza, presenta y describe un conjunto de datos con el propósito de facilitar la interpretación, generalmente, con el apoyo de tablas, medidas o gráficas.



Estadística inferencial

Recopila información de una población a partir de una muestra y por medio de la inducción determina las propiedades de la misma.

Población



Muestra



Software estadístico

**¿Qué es la estadística
y con qué se come?**

Hojas de cálculo



**Industria
open source**



Herramientas de BI y análisis




**Industria
paga**

SPSS®

The SAS logo consists of a blue stylized 'S' icon followed by the lowercase letters 'sas' in a black serif font. Both the icon and the text have a registered trademark symbol (®) to their right.

THE POWER TO KNOW®

Academia



**Otras
herramientas**



GeoAnalytics

Reto


Cuéntame cuál de estas herramientas te parece más afín a tu objetivo y cuál te gustaría aprender después.

Tablas unidimensionales y bidimensionales

**Una imagen vale más
que mil datos**


Tablas unidimensionales

Mes	Ganancias
enero	\$28,361.00
febrero	\$14,744.00
marzo	\$19,407.00
abril	\$15,891.00
mayo	\$21,277.00
junio	\$21,530.00
julio	\$17,990.00
agosto	\$21,838.00
septiembre	\$20,174.00
octubre	\$20,025.00
noviembre	\$48,055.00
diciembre	\$24,318.00




Tablas bidimensionales

Mes	Ganancias
enero	\$28,361.00
febrero	\$14,744.00
marzo	\$19,407.00
abril	\$15,891.00
mayo	\$21,277.00
junio	\$21,530.00
julio	\$17,990.00
agosto	\$21,838.00
septiembre	\$20,174.00
octubre	\$20,025.00
noviembre	\$48,055.00
diciembre	\$24,318.00




Mes	2018	2019	2020	2021
enero	\$ 254.00	\$ 1,396.00	\$ 10,696.00	\$ 16,015.00
febrero	\$ 377.00	\$ 1,084.00	\$ 4,745.00	\$ 8,538.00
marzo	\$ 291.00	\$ 1,679.00	\$ 7,549.00	\$ 9,888.00
abril	\$ 1,146.00	\$ 1,668.00	\$ 2,434.00	\$ 10,643.00
mayo	\$ 820.00	\$ 2,708.00	\$ 2,326.00	\$ 15,423.00
junio	\$ 1,138.00	\$ 3,014.00	\$ 2,982.00	\$ 14,396.00
julio	\$ 694.00	\$ 2,586.00	\$ 3,270.00	\$ 11,440.00
agosto	\$ 486.00	\$ 2,080.00	\$ 5,451.00	\$ 13,821.00
septiembre	\$ 538.00	\$ 3,109.00	\$ 6,614.00	\$ 9,913.00
octubre	\$ 448.00	\$ 3,695.00	\$ 5,153.00	\$ 10,729.00
noviembre	\$ 2,387.00	\$ 6,495.00	\$ 13,128.00	\$ 26,045.00
diciembre	\$ 401.00	\$ 2,030.00	\$ 7,441.00	\$ 14,446.00

Ganancias anuales por mes



Mes	2018	2019	2020	2021	Total
enero	\$254.00	\$1,396.00	\$10,696.00	\$16,015.00	\$28,361.00
febrero	\$377.00	\$1,084.00	\$4,745.00	\$8,538.00	\$14,744.00
marzo	\$291.00	\$1,679.00	\$7,549.00	\$9,888.00	\$19,407.00
abril	\$1,146.00	\$1,668.00	\$2,434.00	\$10,643.00	\$15,891.00
mayo	\$820.00	\$2,708.00	\$2,326.00	\$15,423.00	\$21,277.00
junio	\$1,138.00	\$3,014.00	\$2,982.00	\$14,396.00	\$21,530.00
julio	\$694.00	\$2,586.00	\$3,270.00	\$11,440.00	\$17,990.00
agosto	\$486.00	\$2,080.00	\$5,451.00	\$13,821.00	\$21,838.00
septiembre	\$538.00	\$3,109.00	\$6,614.00	\$9,913.00	\$20,174.00
octubre	\$448.00	\$3,695.00	\$5,153.00	\$10,729.00	\$20,025.00
noviembre	\$2,387.00	\$6,495.00	\$13,128.00	\$26,045.00	\$48,055.00
diciembre	\$401.00	\$2,030.00	\$7,441.00	\$14,446.00	\$24,318.00
Total	\$8,980.00	\$31,544.00	\$71,789.00	\$161,297.00	\$273,610.00

Ganancias anuales por mes



**Datos que
utilizaremos
en el curso**

Reto


Cuéntame en los comentarios si crees que nuestra tabla de Netflix es unidimensional o bidimensional. Quiero leer tus argumentos.

Frecuencia estadística


**Una imagen vale más
que mil datos**

Edición	Sede	Continente
1930	Uruguay	Sudamérica
1934	Italia	Europa
1938	Francia	Europa
1950	Brasil	Sudamérica
1954	Suiza	Europa
1958	Suecia	Europa
1962	Chile	Sudamérica
1966	Inglaterra	Europa
1970	México	Norteamérica
1974	Alemania Federal	Europa
1978	Argentina	Sudamérica
1982	España	Europa
1986	México	Norteamérica
1990	Italia	Europa
1994	Estados Unidos	Norteamérica
1998	Francia	Europa
2002	Corea del Sur y Japón	Asia
2006	Alemania	Europa
2010	Sudáfrica	África
2014	Brasil	Sudamérica
2018	Rusia	Europa
2022	Catar	Asia
2026	Canadá, Estados Unidos y México	Norteamérica

Continente	# Sede
África	1
Asia	2
Europa	11
Norteamérica	4
Sudamérica	5
Total general	23



Type	Cuenta
Movie	6131
TV Show	2676
Total general	8807



Cuenta mundiales Continente sede

Año mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total general
1930-1945			2		1	3
1946-1961			2		1	3
1962-1977			2	1	1	4
1978-1993			2	1	1	4
1994-2009		1	2	1		4
2010-2026	1	1	1	1	1	5
Total general	1	2	11	4	5	23

Frecuencia relativa

Continente	# Sede	% Sede
África	1	4%
Asia	2	9%
Europa	11	48%
Norteamérica	4	17%
Sudamérica	5	22%
Total general	23	100%

Type	Cuenta	%
Movie	6131	69%
TV Show	2676	31%
Total general	8807	100%

Cuenta de Sede	Continente					
Años mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total periodo
1930-1945	0.00%	0.00%	8.70%	0.00%	4.35%	13.04%
1946-1961	0.00%	0.00%	8.70%	0.00%	4.35%	13.04%
1962-1977	0.00%	0.00%	8.70%	4.35%	4.35%	17.39%
1978-1993	0.00%	0.00%	8.70%	4.35%	4.35%	17.39%
1994-2009	0.00%	4.35%	8.70%	4.35%	0.00%	17.39%
2010-2026	4.35%	4.35%	4.35%	4.35%	4.35%	21.74%
Total sede	4.35%	8.70%	47.83%	17.39%	21.74%	100.00%

Reto

De la tabla de Netflix, crea las tablas de frecuencia y frecuencia relativa para:

- Género principal (*main_genre*).
- Clasificación de edades (*rating*) y año de estreno (*release_year*).

Y ahora, ¿qué visualización uso?


**Una imagen vale más
que mil datos**

Diagramas de tallo y hoja


70	65
69	60
67	63
66	66
75	75
68	64
62	64
66	67
74	60
62	68
66	72

6	0,0,2,2,3,4,4,5,6,6,6,6,7,7,8,8,9
7	0,2,4,5,5

Gráfico de puntos




Continentes sedes del mundial




Categoría en Netflix

Gráfico de barras



**Continentes sedes
del mundial**




Categoría en Netflix

Gráfico de barras horizontal




Continentes sedes del mundial




Categoría en Netflix

Gráfico circular (de pastel o pie chart)



Continentes sedes del mundial



Categoría en Netflix

Gráfico de línea

Similar al gráfico de barras, solo que se recomienda para valores dependientes del tiempo.



Gráfico de ojiva


Edad	Ahorro	Acumulado
30	\$5,500.00	\$5,500.00
31	\$5,500.00	\$11,000.00
32	\$5,500.00	\$16,500.00
33	\$5,500.00	\$22,000.00
34	\$5,500.00	\$27,500.00
35	\$5,500.00	\$33,000.00
36	\$5,500.00	\$38,500.00
37	\$5,500.00	\$44,000.00
38	\$5,500.00	\$49,500.00
39	\$5,500.00	\$55,000.00
40	\$5,500.00	\$60,500.00
41	\$5,500.00	\$66,000.00



Diagramas de venn



Histograma



Distribuciones conjuntas

Estadística descriptiva

Frecuencia relativa a filas

Cuenta mundiales	Continente sede					
Años mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total periodo
1930-1945	0.00%	0.00%	66.67%	0.00%	33.33%	100.00%
1946-1961	0.00%	0.00%	66.67%	0.00%	33.33%	100.00%
1962-1977	0.00%	0.00%	50.00%	25.00%	25.00%	100.00%
1978-1993	0.00%	0.00%	50.00%	25.00%	25.00%	100.00%
1994-2009	0.00%	25.00%	50.00%	25.00%	0.00%	100.00%
2010-2026	20.00%	20.00%	20.00%	20.00%	20.00%	100.00%
Total sede	4.35%	8.70%	47.83%	17.39%	21.74%	100.00%

Cuenta mundiales		Continente sede				
Años mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total periodo
1930-1945	0.00%	0.00%	66.67%	0.00%	33.33%	100.00%
1946-1961	0.00%	0.00%	66.67%	0.00%	33.33%	100.00%
1962-1977	0.00%	0.00%	50.00%	25.00%	25.00%	100.00%
1978-1993	0.00%	0.00%	50.00%	25.00%	25.00%	100.00%
1994-2009	0.00%	25.00%	50.00%	25.00%	0.00%	100.00%
2010-2026	20.00%	20.00%	20.00%	20.00%	20.00%	100.00%
Total sede	4.35%	8.70%	47.83%	17.39%	21.74%	100.00%

Cuenta mundiales	Continente sede					
Años mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total periodo
1930-1945	0.00%	0.00%	66.67%	0.00%	33.33%	100.00%
1946-1961	0.00%	0.00%	66.67%	0.00%	33.33%	100.00%
1962-1977	0.00%	0.00%	50.00%	25.00%	25.00%	100.00%
1978-1993	0.00%	0.00%	50.00%	25.00%	25.00%	100.00%
1994-2009	0.00%	25.00%	50.00%	25.00%	0.00%	100.00%
2010-2026	20.00%	20.00%	20.00%	20.00%	20.00%	100.00%
Total sede	4.35%	8.70%	47.83%	17.39%	21.74%	100.00%

Frecuencia relativa a columnas

Sobre continente	Continente					
Años mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total periodo
1930-1945	0.00%	0.00%	18.18%	0.00%	20.00%	13.04%
1946-1961	0.00%	0.00%	18.18%	0.00%	20.00%	13.04%
1962-1977	0.00%	0.00%	18.18%	25.00%	20.00%	17.39%
1978-1993	0.00%	0.00%	18.18%	25.00%	20.00%	17.39%
1994-2009	0.00%	50.00%	18.18%	25.00%	0.00%	17.39%
2010-2026	100.00%	50.00%	9.09%	25.00%	20.00%	21.74%
Total sede	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%

Sobre continente	Continente					
Años mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total periodo
1930-1945	0.00%	0.00%	18.18%	0.00%	20.00%	13.04%
1946-1961	0.00%	0.00%	18.18%	0.00%	20.00%	13.04%
1962-1977	0.00%	0.00%	18.18%	25.00%	20.00%	17.39%
1978-1993	0.00%	0.00%	18.18%	25.00%	20.00%	17.39%
1994-2009	0.00%	50.00%	18.18%	25.00%	0.00%	17.39%
2010-2026	100.00%	50.00%	9.09%	25.00%	20.00%	21.74%
Total sede	100.00%	100.00%	100.00%	100.00%	100.00%	100.00%

**Frecuencia
relativa total**

Sobre periodo de año	Continente					
Años mundial	África	Asia	Europa	Norteamérica	Sudamérica	Total periodo
1930-1945	0.00%	0.00%	8.70%	0.00%	4.35%	13.04%
1946-1961	0.00%	0.00%	8.70%	0.00%	4.35%	13.04%
1962-1977	0.00%	0.00%	8.70%	4.35%	4.35%	17.39%
1978-1993	0.00%	0.00%	8.70%	4.35%	4.35%	17.39%
1994-2009	0.00%	4.35%	8.70%	4.35%	0.00%	17.39%
2010-2026	4.35%	4.35%	4.35%	4.35%	4.35%	21.74%
Total sede	4.35%	8.70%	47.83%	17.39%	21.74%	100.00%



“

En una distribución conjunta, mostramos la distribución de un conjunto de datos respecto a la distribución de otro conjunto de datos

”



100 personas entrevistadas		Kilos perdidos			
		0 - 2	2 - 4	4 - 6	6 +
Horas durmiendo	0 - 3	4%	2%	2%	1%
	3 - 6	8%	6%	5%	0%
	6 - 9	1%	17%	10%	4%
	9 - 12	3%	3%	12%	9%
	12 +	2%	3%	4%	4%

Distribución marginal

100 personas entrevistadas		Kilos perdidos				Total
		0 - 2	2 - 4	4 - 6	6 +	
Horas durmiendo	0 - 3	4%	2%	2%	1%	9%
	3 - 6	8%	6%	5%	0%	19%
	6 - 9	1%	17%	10%	4%	32%
	9 - 12	3%	3%	12%	9%	27%
	12 +	2%	3%	4%	4%	13%
	Total	18%	31%	33%	18%	100%

Marginal columnar

Distribución por kilos perdidos

	Kilos perdidos				Total
	0 - 2	2 - 4	4 - 6	6 +	
Total	18%	31%	33%	18%	100%

Marginal por filas

Distribución por horas dormidas

Horas durmiendo	Total	
	0 - 3	9%
	3 - 6	19%
	6 - 9	32%
	9 - 12	27%
	12 +	13%
	Total	100%

Distribución condicional

100 personas entrevistadas		Kilos perdidos				Total
		0 - 2	2 - 4	4 - 6	6 +	
Horas durmiendo	0 - 3	44%	22%	22%	11%	100%
	3 - 6	42%	32%	26%	0%	100%
	6 - 9	3%	53%	31%	13%	100%
	9 - 12	11%	11%	44%	33%	100%
	12 +	15%	23%	31%	31%	100%

100 personas entrevistadas		Kilos perdidos				
		0 - 2	2 - 4	4 - 6	6 +	Total
Horas durmiendo	0 - 3	44%	22%	22%	11%	100%
	3 - 6	42%	32%	26%	0%	100%
	6 - 9	3%	53%	31%	13%	100%
	9 - 12	11%	11%	44%	33%	100%
	12 +	15%	23%	31%	31%	100%

100 personas entrevistadas		Kilos perdidos			
		0 - 2	2 - 4	4 - 6	6 +
Horas durmiendo	0 - 3	22%	6%	6%	6%
	3 - 6	44%	19%	15%	0%
	6 - 9	6%	55%	30%	22%
	9 - 12	17%	10%	36%	50%
	12 +	11%	10%	12%	22%
Total		100%	100%	100%	100%

100 personas entrevistadas		Kilos perdidos			
		0 - 2	2 - 4	4 - 6	6 +
Horas durmiendo	0 - 3	22%	6%	6%	6%
	3 - 6	44%	19%	15%	0%
	6 - 9	6%	55%	30%	22%
	9 - 12	17%	10%	36%	50%
	12 +	11%	10%	12%	22%
	Total	100%	100%	100%	100%

Reto


Con nuestro dataset de Netflix, encuentra la distribución conjunta entre el rating/clasificación de edad y el género principal.

Medidas de tendencia central

Estadística descriptiva

Media


Promedio de los datos.



$$\bar{X} = \frac{x_1 + x_2 + x_3 + \cdots + x_n}{N}$$

Mediana

Dato o valor que está justo en el centro de todos.



Mediana

$$x_{\frac{N+1}{2}} \text{ si } N \text{ es impar}$$

$$\frac{1}{2} \cdot \left(x_{\frac{N}{2}} + x_{\frac{N}{2}+1} \right) \text{ si } N \text{ es par}$$

$$x_{\frac{N+1}{2}} \text{ si } N \text{ es impar}$$


7, 9, 5, 2, 2, 4, 1

$$\frac{1}{2} \cdot \left(x_{\frac{N}{2}} + x_{\frac{N}{2}+1} \right) \text{ si } N \text{ es par}$$


2, 3, 5, 7, 3, 4, 9, 1

Moda

Dato o valor que más se repite.



Bimodal o sin moda



7, 6, 6, 3, 4, 4, 4,
4, 5, 5, 9, 2, 8, 8

xi	#
2	
3	
4	
5	
6	
7	
8	
9	

5, 2, 2, 2, 2, 3, 3,
3, 3, 5, 5, 7, 9, 9

xi	#
2	
3	
5	
7	
9	
9	

Medidas de dispersión: rango e IQR

Estadística Descriptiva

Rango




Diagrama de tallo y hoja


Puntuaciones

6	0	0	4	5	5	5	6	6	6	7	7	7	8	9
7	2	2	3	3	4	5	6							

Mínimo: 60

Máximo: 76

Rango intercuartílico (RIQ o IQR)



21 puntuaciones en un examen

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----

Desplazamiento y escala de valores

Estadística Descriptiva


60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----

Media	68.6
Mediana	67
Moda	66
Rango	17
IQR	7

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----


Media	68.6
Mediana	67
Moda	66
Rango	17
IQR	7



Desplazamiento (suma y resta)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77


Media	68.6	
Mediana	67	
Moda	66	
Rango	17	
IQR	7	



Desplazamiento (suma y resta)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
64	64	68	69	69	70	70	70	71	71	71	72	73	76	76	77	77	78	79	80	81


Media	68.6	
Mediana	67	
Moda	66	
Rango	17	
IQR	7	



Desplazamiento (suma y resta)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
64	64	68	69	69	70	70	70	71	71	71	72	73	76	76	77	77	78	79	80	81


Media	68.6	72.6
Mediana	67	71
Moda	66	70
Rango	17	17
IQR	7	7



Desplazamiento (suma y resta)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
64	64	68	69	69	70	70	70	71	71	71	72	73	76	76	77	77	78	79	80	81


Media	68.6	72.6
Mediana	67	71
Moda	66	70
Rango	17	17
IQR	7	7



Escalar (multiplicación y división)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77


Media	68.6	
Mediana	67	
Moda	66	
Rango	17	
IQR	7	



Escalar (multiplicación y división)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
120	120	128	130	130	132	132	132	134	134	134	136	138	144	144	146	146	148	150	152	154


Media	68.6	
Mediana	67	
Moda	66	
Rango	17	
IQR	7	



Escalar (multiplicación y división)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
120	120	128	130	130	132	132	132	134	134	134	136	138	144	144	146	146	148	150	152	154


Media	68.6	137.2
Mediana	67	134
Moda	66	132
Rango	17	34
IQR	7	14



Escalar (multiplicación y división)

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
120	120	128	130	130	132	132	132	134	134	134	136	138	144	144	146	146	148	150	152	154


Media	68.6	137.2
Mediana	67	134
Moda	66	132
Rango	17	34
IQR	7	14



Añadir o quitar un punto de datos en el conjunto

60	60	64	65	65	66	66	66	67	67	67			68	69	72	72	73	73	74	75	76	77
----	----	----	----	----	----	----	----	----	----	----	--	--	----	----	----	----	----	----	----	----	----	----


Media	68.6	
Mediana	67	
Moda	66	
Rango	17	
IQR	7	



Box plots y el resumen de 5 números


Estadística Descriptiva

Box plot



Resumen de 5 números


Mínimo	
Q1	
Mediana	
Q3	
Máximo	



Resumen de 5 números

60	60	64	65	65	66	66	66	67	67	67	68	69	72	72	73	73	74	75	76	77
----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----	----

Mínimo	
Q1	
Mediana	
Q3	
Máximo	



Media, varianza y desviación estándar

Representación de datos

Media

Media

$$\mu = \frac{\sum_{i=1}^N x_i}{N}$$

Poblacional

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Muestral

Varianza

Varianza

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

Poblacional

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

Muestral

Varianza no sesgada

Muestral

$$s_{n-1}^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Desviación estándar

Poblacional y muestral

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

Poblacional

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Muestral


Reto

**Calcula la media,
varianza y desviación
estándar poblacional y
muestral de años de
estreno.**


Histogramas, polígonos de frecuencia y curvas de densidad

Representación de datos

Duración Películas




Duración en minutos




Histograma de frecuencia relativa

Duración en minutos




Duración en minutos película (% del total)




Polígono de frecuencia

Duración en minutos




Duración en minutos




Curva de densidad

Duración películas




Duración películas





Distribuciones simétricas y asimétricas

Representación de datos

Duración películas



Distribuciones simétricas




Ejemplos

Distribuciones simétricas


- Notas en un examen.
- Errores de medida.
- Presión sanguínea.
- Tamaño de las piezas producidas por una máquina.

Distribución normal



- Llamada “de campana” o “de Gauss” / “Gaussiana”
- Sus medidas de tendencia central son idénticas.
- Su «50% central» está dentro de $\frac{2}{3}$ de desviación estándar hacia la izquierda y derecha de la media.



Regla empírica (68-95-99.7)



Distribuciones asimétricas




Ejemplos


- Notas en un examen muy difícil.
- Año de estreno de películas.

Valores atípicos

- Valores atípicos bajos
 - $Q1 - 1.5 (IQR)$
- Valores atípicos altos
 - $Q3 + 1.5 (IQR)$

Minimo	1925
Q1	2013
Mediana	2017
Q3	2019
Máximo	2021
<i>Moda</i>	<i>2018</i>





Métodos de recopilación de datos

Muestra y sesgo

Estudio observacional



Recopilación de datos

- **Tablas
unidimensionales**
- **Tablas
bidimensionales**

Estudio experimental



Estudio experimental

- Aleatorización
- Grupo de control y grupo de estudio
- Replicación
- Bloqueo (*matched pairs*)


Muestreo y sesgo

Muestra y sesgo

Mediciones

- Parámetro
- Estadístico

Población



Sesgo en la toma de muestras

Sesgo de respuesta



- Medición incorrecta.
- Deseabilidad social.
- Preguntas inductivas o capciosas.



Sesgo de infracobertura

- **Selección.**
- **Respuesta voluntaria.**
- **Muestreo a
conveniencia.**

Sesgo de no respuesta



Dirección del sesgo

¿Qué es la probabilidad?

¿Y la probabilidad?



“

**La probabilidad es la ciencia
que mide la certidumbre de
que ocurra o no un evento.**

¿Qué es la probabilidad?



Probabilidad simple

$$P(\text{evento}) = \frac{\text{Evento que cumple con nuestro criterio}}{\text{La colección de todos los resultados posibles}}$$

Probabilidad simple

$$P(\text{evento}) = \frac{\text{Evento que cumple con nuestro criterio}}{\text{La colección de todos los resultados posibles}}$$

$$P(\text{evento}) = \frac{\text{Evento que cumple con nuestro criterio}}{\text{La colección de todos los resultados igualmente posibles}}$$

Probabilidad experimental

$$P(\text{evento}) = \frac{\text{Evento que cumple con nuestro criterio}}{\text{La colección de todos los resultados posibles}}$$

Regla de la suma, unión e intersección

¿Y la probabilidad?


	1	2	3	4	5	6
1	(1, 1)	(1, 2)	(1, 3)	(1, 4)	(1, 5)	(1, 6)
2	(2, 1)	(2, 2)	(2, 3)	(2, 4)	(2, 5)	(2, 6)
3	(3, 1)	(3, 2)	(3, 3)	(3, 4)	(3, 5)	(3, 6)
4	(4, 1)	(4, 2)	(4, 3)	(4, 4)	(4, 5)	(4, 6)
5	(5, 1)	(5, 2)	(5, 3)	(5, 4)	(5, 5)	(5, 6)
6	(6, 1)	(6, 2)	(6, 3)	(6, 4)	(6, 5)	(6, 6)

	1	2	3	4	5	6
1	(1, 1)	(1, 2)	(1, 3)	(1, 4)	(1, 5)	(1, 6)
2	(2, 1)	(2, 2)	(2, 3)	(2, 4)	(2, 5)	(2, 6)
3	(3, 1)	(3, 2)	(3, 3)	(3, 4)	(3, 5)	(3, 6)
4	(4, 1)	(4, 2)	(4, 3)	(4, 4)	(4, 5)	(4, 6)
5	(5, 1)	(5, 2)	(5, 3)	(5, 4)	(5, 5)	(5, 6)
6	(6, 1)	(6, 2)	(6, 3)	(6, 4)	(6, 5)	(6, 6)

	1	2	3	4	5	6
1	(1, 1)	(1, 2)	(1, 3)	(1, 4)	(1, 5)	(1, 6)
2	(2, 1)	(2, 2)	(2, 3)	(2, 4)	(2, 5)	(2, 6)
3	(3, 1)	(3, 2)	(3, 3)	(3, 4)	(3, 5)	(3, 6)
4	(4, 1)	(4, 2)	(4, 3)	(4, 4)	(4, 5)	(4, 6)
5	(5, 1)	(5, 2)	(5, 3)	(5, 4)	(5, 5)	(5, 6)
6	(6, 1)	(6, 2)	(6, 3)	(6, 4)	(6, 5)	(6, 6)

$$P(1 \text{ o } par) = P(1) + P(par)$$

$$= \frac{11}{36} + \frac{18}{36} = \frac{29}{36}$$




	1	2	3	4	5	6
1	(1, 1)	(1, 2)	(1, 3)	(1, 4)	(1, 5)	(1, 6)
2	(2, 1)	(2, 2)	(2, 3)	(2, 4)	(2, 5)	(2, 6)
3	(3, 1)	(3, 2)	(3, 3)	(3, 4)	(3, 5)	(3, 6)
4	(4, 1)	(4, 2)	(4, 3)	(4, 4)	(4, 5)	(4, 6)
5	(5, 1)	(5, 2)	(5, 3)	(5, 4)	(5, 5)	(5, 6)
6	(6, 1)	(6, 2)	(6, 3)	(6, 4)	(6, 5)	(6, 6)

$$P(1 \text{ o } par) = P(1) + P(par) - P(1 \text{ y } par)$$

$$P(1 \text{ o } par) = P(1) + P(par) - P(1 \text{ y } par)$$

$$= \frac{11}{36} + \frac{18}{36} - \frac{5}{36} = \frac{24}{36} = \frac{2}{3}$$



$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A \cup B) = P(A) + P(B) - 0$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A \cup B) = P(A) + P(B) - 0$$

$$P(A \cup B) = P(A) + P(B)$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Deporte	LATAM	EEUU	Total
Futbol	22	16	38
Básquetbol	13	8	21
Otra	25	16	41
Total	60	40	100

1. ¿Cuál es la probabilidad de que un participante sea de LATAM?

Deporte	LATAM	EEUU	Total
Futbol	22	16	38
Básquetbol	13	8	21
Otra	25	16	41
Total	60	40	100

2. ¿Cuál es la probabilidad de que el deporte favorito de un participante sea el básquetbol?

Deporte	LATAM	EEUU	Total
Futbol	22	16	38
Básquetbol	13	8	21
Otra	25	16	41
Total	60	40	100

3. ¿Cuál es la probabilidad de que un participante sea de EEUU o prefiera un deporte diferente al fútbol o al básquetbol?

Probabilidad condicional

¿Y la probabilidad?

La regla de la multiplicación

$$P(A \text{ y } B) = P(A) \cdot P(B)$$

Eventos independientes



¿La probabilidad sube?

$$P(\textit{encestar}) = P(C) \\ = 70\% = 0.7$$



¿La probabilidad sube?

$$\begin{aligned}P(\textit{encestar}) &= P(C) \\ &= 70\% = 0.7\end{aligned}$$

$$\begin{aligned}P(\textit{encestar 5 veces seguidas}) \\ &= P(C) \cdot P(C) \cdot P(C) \cdot P(C) \cdot P(C)\end{aligned}$$



¿La probabilidad sube?

$$\begin{aligned}P(\textit{encestar}) &= P(C) \\ &= 70\% = 0.7\end{aligned}$$


$$\begin{aligned}P(\textit{encestar 5 veces seguidas}) \\ &= P(C) \cdot P(C) \cdot P(C) \cdot P(C) \cdot P(C)\end{aligned}$$

$$\begin{aligned}&= 0.7 \cdot 0.7 \cdot 0.7 \cdot 0.7 \cdot 0.7 \\ &= (0.7)^5 \\ &= 0.16807\end{aligned}$$

$$= 16.81\%$$



Eventos dependientes



Probabilidad condicional

$$P(A|B)$$

**“La probabilidad de que
suceda A sucedido B”**

Ejemplo

Tenemos dos dados. Uno es justo y el otro está ponderado para aterrizar en 6 el 50 % del tiempo. Hay una probabilidad igual para las otras cinco caras en el dado sesgado.

Sin saber cuál estamos eligiendo, tomamos uno de los dados, lo lanzamos y obtenemos un 6. ¿Cuál es la probabilidad de que hayamos lanzado el dado sesgado?

Teorema de Bayes

¿Y la probabilidad?

$$P(A|B) = \frac{P(B|A) \cdot P(A)P(B)}{P(B)}$$

$\text{¿ } P(\text{cargado} \mid 6)?$
 $P(6 \mid \text{cargado}) =$
 $P(\text{cargado}) =$
 $P(6) =$



$$P(\text{cargado y } 6) =$$

$$P(\text{justo y } 6) =$$

$$P(6) =$$

$$P(A|B) = \frac{P(B|A) \cdot P(A)P(B)}{P(B)}$$

Combinaciones y permutaciones

Variables aleatorias discretas

Permutación

$${}_nP_k = \frac{n!}{(n-k)!}$$

- n es el número total de elementos que tenemos.
- k es el número de elementos que queremos organizar.

Combinación

$${}_nC_k = \frac{n!}{k!(n-k)!}$$

- n es el número total de elementos que tenemos.
- k es el número de elementos que queremos organizar.

$${}_nC_k = \frac{n!}{k! (n - k)!} = \binom{n}{k}$$

Variables aleatorias discretas

Variables aleatorias discretas

**¿Qué es una
variable aleatoria
discreta?**

Valor esperado

X	P(X)
x1	p1
x2	p2
x3	p3

$$E(X) = \mu = \sum_i^n x_i \cdot p_i$$

Varianza y desviación estándar

X	P(X)
x1	p1
x2	p2
x3	p3


$$\sigma_X^2 = \sum_{i=1}^n (X_i - \mu)^2 P(X_i)$$

$$\sqrt{\sigma_X^2} = \sqrt{\sum_{i=1}^n (X_i - \mu)^2 P(X_i)}$$

Tipos de variables aleatorias discretas

Binomial


- Cada ensayo debe ser independiente.
- Cada prueba se puede llamar un "éxito" o "fracaso".
- Hay un número fijo de intentos.
- La probabilidad de éxito en cada ensayo es constante.



$$P(k \text{ éxitos en } n \text{ intentos}) = \binom{n}{k} p^k (1 - p)^{n-k}$$

Poisson

- El experimento cuenta el número de ocurrencias de un evento sobre alguna otra medida (de longitud, de tiempo, etc.).
- La media es la misma para cada intervalo.
- El conteo de eventos en cada intervalo es independiente del siguiente intervalo.



Poisson

- Los intervalos no se superponen.
- La probabilidad de que ocurra el evento es proporcional al periodo.

$$P(x) = \frac{\lambda^x e^{-\lambda}}{x!}$$

Bernoulli

- Categoría especial de variables aleatorias binomiales.
- Específicamente, tenemos exactamente una sola prueba y definimos "éxito" como 1 y "fracaso" como 0.

Bernoulli

$$\mu = \%fallo(0) + \%éxito(1) = \%éxito$$

$$\sigma^2 = peso\ de\ fallo(1 - p_e)^2 + peso\ de\ éxito(p_e)^2$$

Geométrica

- Cada ensayo debe ser independiente.
- Cada prueba se puede llamar un "éxito" o "fracaso".
- La probabilidad de éxito en cada ensayo es constante.
- El evento de éxito sucede en el intento S .

Geométrica

$$P(S = n) = p(1 - p)^{n-1}$$

$$\mu_X = E(X) = \frac{1}{p}$$





$$\sigma_X^2 = \frac{1 - p}{p^2}$$

¿Correlación o causalidad?

Correlación y causalidad

Gráficos de dispersión e introducción a la regresión

Correlación y causalidad



Regresión

Ecuación de la recta

$$\hat{y} = a + bx,$$

$$b = \frac{n \sum xy - \sum x \sum y}{n \sum x^2 - (\sum x)^2}$$

$$a = \frac{\sum y - b \sum x}{n}$$


- $\sum xy$ es la suma de todos los productos de x e y
- $\sum x$ es la suma de todos los valores de x
- $\sum y$ es la suma de todos los valores de y
- $\sum x^2$ es la suma de todos los valores de x al cuadrado, y
- $(\sum x)^2$ es el cuadrado de la suma de todos los valores de x.

Descripción de la tendencia


Descripción de los datos

- **Forma (lineal, parabólica, sinusoidal, etc.).**
- **Dirección (positiva, negativa).**
- **Fuerza (fuerte, débil).**
- **Valores atípicos.**


Forma



Correlación lineal




Correlación parabólica




Sin correlación

Dirección




Lineal
positiva


Lineal
negativa



Fuerza y valores atípicos



**Relación lineal
moderada**



**Relación lineal
fuerte**


Reto

Gráfica la dispersión de los datos y su línea de regresión:

- Percepción de corrupción vs. nivel de felicidad.**
- Apoyo social (servicios públicos) vs. nivel de felicidad.**

**¿Qué aprender con
tus nuevos poderes?**

**I HAVE NO IDEA
WHAT I'M DOING**



¿Qué aprender?

- **Profundizar en estadística**
- **Análisis de datos**
- **Finanzas**
- **Marketing y publicidad digital**
- **Negocios y emprendimientos**
- **Ciencias**



¡Felicitaciones!

