




El Arte de Equilibrar el Costo y el Desempeño de la Inferencia de IA

E-BOOK



Este libro electrónico es su hoja de ruta esencial para navegar por las complejidades de la infraestructura en el acelerado panorama tecnológico actual. Esta guía, adaptada para líderes de TI que se embarcan en su viaje hacia la IA, desmitifica cómo los casos de uso de IA condicionan directamente la medición del desempeño y la optimización de la infraestructura.

Las cargas de trabajo de IA exigen una infraestructura que ofrezca alto desempeño, confiabilidad y eficiencia. Pero ¿cómo determina usted si su infraestructura puede cumplir con las demandas de su caso de uso específico de IA?

Este libro electrónico explora:

- **El Papel de los Casos de Uso en la Medición del Desempeño:** Comprenda cómo las diferentes aplicaciones de IA impulsan requisitos de infraestructura únicos.
- **Métricas Clave para la Inferencia de IA:** Aprenda qué medir (latencia, rendimiento, eficiencia energética y más) para garantizar el éxito.
- **Mejores Prácticas para la Optimización de la Infraestructura:** Obtenga estrategias factibles para alinear su pila tecnológica con sus objetivos empresariales.

Con información, frameworks y ejemplos, la *Guía para Líderes de TI sobre la Inferencia y el Desempeño de IA* le proporciona el conocimiento necesario para evaluar, implementar y escalar soluciones de IA de manera efectiva, lo que la convierte en una lectura obligatoria para los tomadores de decisiones que quieren liderar con confianza en la era de la IA.

Índice

Qué es el Desempeño de Inferencia y Por Qué es Importante	5
Abordar el Desafío del Costo por Token	5
Estudio de Caso de Cliente: Wealthsimple	7
Cómo los Casos de Uso Impactan en la Inferencia	9
Chatbot	9
Resumen	9
Respuestas a Preguntas	10
Agentes de IA.....	10
Estudio de Caso de Cliente: Perplexity	11
Factores de Implementación que Afectan el Desempeño de la Inferencia ...	12
Consideraciones sobre la Arquitectura de Hardware	12
Arquitectura de GPU Optimizada para la Inferencia	12
Emparejamiento de GPU con CPU con Eficiencia Energética	13
Múltiples GPU Trabajan Juntas como Una durante la Inferencia	14
Tamaño del Modelo	16
Maximización de la Utilización por Medio de la Concurrencia de Modelos	16
Múltiples Modalidades en Modelos	19
Optimización del Desempeño con Técnicas de Lote Avanzadas	19
Lotes Dinámicos	20
Procesamiento Secuencial por Lotes.....	20
Procesamiento por Lotes Inflight	21
Paralelización de la Inferencia para Grandes Modelos:	
Métodos y Compensaciones Clave	23
Paralelismo de Datos (DP)	23
Impacto en el Desempeño:.....	24
Paralelismo Tensorial (TP)	24
Paralelismo de Pipeline (PP)	25
Paralelismo de Expertos (EP)	25
Combinación de Métodos de Paralelismo para un Desempeño Óptimo	26

Índice (cont.)

Habilitación del Desempeño de la Inferencia de IA y la Eficiencia de Costos en la Nube	28
Estudio de Caso de Cliente: Amdocs.....	29
Escalado de la Inferencia de IA para Satisfacer la Demanda Fluctuante	30
Flexibilidad con Kubernetes y la Plataforma de Inferencia de IA de NVIDIA	30
Optimización de los Pipelines de IA con Conjuntos de Modelos	33
El Papel de NVIDIA Dynamo-Triton en los Conjuntos de Modelos	33
Beneficios de los Conjuntos de Modelos con Triton	34
Ejemplo Práctico: Aplicaciones Generativas Impulsadas por IA	34
El Poder de los Conjuntos de Modelos para la Optimización de la IA	35
Estudio de Caso: Let's Enhance Convierte Fotos de Productos en Hermosos Recursos de Marketing	35
Técnicas de Inferencia Avanzadas para Impulsar el Desempeño	36
Prellenado en Fragmentos: Maximización de la Utilización de GPU y Reducción de la Latencia.....	36
Atención de Multibloques: Aumento del Rendimiento con Contextos Largos	37
Reutilización Temprana de Caché de KV: Reducción del Tiempo al Primer Token....	37
Servicio Desagregado: Recursos Independientes y Escalado Desacoplado	37
Decodificación Especulativa: Aceleración de la Generación de Tokens	38
Enrutamiento Sensible al Contexto: Evitar la Recomputación de Caché de KV	39
Liberar el Futuro de la Inferencia de IA.....	40
Primeros Pasos con la Plataforma de Inferencia de IA de NVIDIA	40

Qué es el Desempeño de Inferencia y Por Qué es Importante

[La inferencia de IA](#) es la que lleva IA al mundo real, resolviendo desafíos de implementación avanzados para habilitar aplicaciones, desde la escritura de código hasta el resumen de documentos largos, e incluso la generación de imágenes y videos cortos. El potencial de la inferencia para automatizar workflows, crear nuevos modelos empresariales e impulsar productos innovadores es transformador, especialmente para los directores de sistemas de información y los líderes de TI encargados de impulsar la innovación con IA dentro de su empresa.

Sin embargo, con esta oportunidad viene un desafío clave: la administración de los costos recurrentes asociados con el escalado de las cargas de trabajo de inferencia, así como con la necesidad de equilibrar latencia y desempeño.

Abordar el Desafío del Costo por Token

Al mantener la infraestructura de IA en las instalaciones, cada solicitud de inferencia atendida debe generar ingresos suficientes para cubrir los costos de los aceleradores de hardware, el software de inferencia, la optimización y la administración de inferencia continuas, y más. Para aquellos que utilizan la infraestructura como servicio, la carga financiera cambia a las instancias de computación acelerada mensuales o anuales y las tarifas de inferencia de Software como Servicio (SaaS). Independientemente del modelo de implementación, garantizar que el rendimiento de la inversión de la inferencia de IA justifique estos costos es una preocupación crítica para los líderes de TI.

Nuestra misión es ayudar a las organizaciones a abordar estos desafíos mediante la optimización del desempeño de IA y la reducción del costo de inferencia. Al mejorar la eficiencia de los sistemas de inferencia de IA, NVIDIA permite a las empresas reducir los costos y, al mismo tiempo, mantener la escalabilidad, el desempeño y la experiencia de usuario necesarios para cumplir con las crecientes demandas de implementación de IA.

Los costos de inferencia están estrechamente correlacionados con dos factores clave. El primero es el desempeño o el rendimiento de la propia plataforma de IA. Cuantas más solicitudes pueda manejar un sistema de manera eficiente, mejor podrán las organizaciones distribuir los costos entre las solicitudes entrantes, lo que reduce el costo por solicitud. Sin embargo, a medida que los modelos de IA generan tokens en respuesta a las solicitudes, cuya complejidad y tipo pueden variar significativamente, el *costo por token* se convierte en una métrica esencial para evaluar el desempeño del sistema y la eficiencia de costos generales.

Sin embargo, la reducción del costo por token debe equilibrarse con el mantenimiento de una experiencia de usuario de alta calidad. La maximización del volumen de solicitudes a expensas de la experiencia del usuario puede reducir la adopción de la aplicación o el servicio habilitado para IA. Una experiencia de usuario deficiente puede provocar la deserción de clientes, lo que, a su vez, erosiona los ingresos. Por lo tanto, es esencial medir el costo por token y la *latencia* del sistema.

La latencia normalmente se mide en dos dimensiones: el *Tiempo hasta el Primer Token* (TTFT) y el *Tiempo por Token de Salida* (TPOT). Más adelante exploraremos con más detalle el modo en que la optimización de estas dimensiones a menudo exige compensaciones. El aumento de uno puede conducir al deterioro de otro, por lo que es crucial para las organizaciones lograr el equilibrio correcto.




Figura 1 La Optimización del Tiempo hasta el Primer Token y del Tiempo entre Tokens a Menudo Exige Tres Compensaciones si Estos no se Equilibran Correctamente

Para tener en cuenta estas interdependencias, los líderes de TI están comenzando a medir el *Goodput*, definido como el rendimiento que logra un sistema, manteniendo los niveles objetivo de TTFT y TPOT. Esta métrica permite a las organizaciones evaluar el desempeño de una manera más holística, lo que garantiza que el rendimiento, la latencia y el costo estén alineados para respaldar la eficiencia operativa y una experiencia de usuario excepcional.

El segundo factor crítico que impulsa los costos de Inferencia es el tiempo de lanzamiento al mercado. El panorama de la IA está evolucionando rápidamente, y ser el primero en salir al mercado puede representar una ventaja competitiva importante. Sin embargo, una pila de software de inferencia no confiable, mal probada o carente de documentación integral y de un sólido soporte de la comunidad puede provocar retrasos costosos, desafíos de integración y curvas de aprendizaje empinadas para los equipos de desarrollo internos.

Estos obstáculos combinados dificultan la capacidad de una organización para capitalizar las oportunidades emergentes. Si bien la cuantificación del impacto exacto de estos problemas en los costos de inferencia puede ser desafiante, el efecto es tangible, y los líderes de TI deben incorporarlo en su estrategia general de gestión de costos de inferencia.

A medida que continúe leyendo, profundizaremos en cómo puede abordar estos factores para optimizar el desempeño de la Inferencia de IA, reducir los costos y maximizar el valor a largo plazo de sus inversiones en IA.

Estudio de Caso de Cliente: Wealthsimple



Figura 2 Wealthsimple Usó la Plataforma de Inferencia de IA de NVIDIA para Reducir el Tiempo de Entrega de Modelos y Mejorar su Experiencia General del Cliente

Wealthsimple, una empresa líder en gestión de inversiones canadiense, buscó mejorar su implementación de modelos de machine learning (ML) para mejorar las experiencias de los clientes. Al gestionar más de \$50 mil millones en activos bajo administración, la compañía enfrentó retrasos en la implementación de nuevos modelos debido a una plataforma de inferencia de IA no estandarizada. Para abordar esto, Wealthsimple recurrió a la plataforma de inferencia de IA de NVIDIA, logrando así resultados notables.

En los últimos 12 meses, Wealthsimple implementó más de 30 modelos de IA, lo que generó 145 millones de predicciones. Con la plataforma de NVIDIA implementada, la compañía redujo el tiempo de entrega de modelos de meses a menos de 15 minutos, mejorando drásticamente la velocidad y la eficiencia. Se ha comprobado la confiabilidad de la plataforma, sin tickets de TI relacionados con la inferencia de IA en el último año y medio.

NVIDIA Triton Inference Server mejoró la capacidad de Wealthsimple para proporcionar personalización impulsada por ML, como la detección de fraude y la optimización de transacciones, lo que garantiza procesos financieros más rápidos y precisos. La plataforma también mejoró el tiempo de actividad del 95 % al 99.999 %, lo que elimina retrasos para los clientes y agiliza las transferencias electrónicas.

Wealthsimple aprovecha la computación acelerada de NVIDIA en la nube para ejecutar sus modelos de manera eficiente, con el soporte de NVIDIA AI Enterprise para garantizar la seguridad y la estabilidad. Esta transformación ha permitido a Wealthsimple proporcionar servicios de vanguardia minimizando el tiempo de inactividad, lo que mejora significativamente sus servicios financieros impulsados por ML.

Resultados Clave:

- Tiempo de implementación de modelos reducido de varios meses a 15 minutos
- Aumento del tiempo de actividad de inferencia del 95 % al 99.999 %
- Latencia de servicio de inferencia reducida en un 20 %
- Se entregaron 145 millones de predicciones con cero tickets de TI

Cómo los Casos de Uso Impactan en la Inferencia

A la hora de evaluar el desempeño de los diferentes aceleradores de IA, puede ser tentador basar las decisiones de infraestructura de hardware en un solo punto de referencia. Sin embargo, con el tiempo, este enfoque demasiado simplificado a menudo conduce a un aumento de los costos de los sistemas. Los sistemas provistos inicialmente pueden no cumplir con las demandas de desempeño de un caso de uso específico, lo que requerirá inversiones futuras en recursos adicionales. Esto ocurre porque las cargas de trabajo de inferencia de diferentes casos de uso tienen demandas variables de recursos de computación acelerados y optimizaciones de pila de software, factores que son cruciales para lograr el costo total de propiedad (TCO) deseado y garantizar una interactividad óptima con el usuario.

Chatbot

Considere, por ejemplo, los chatbots impulsados por LLM que se usan comúnmente en los workflows de comercio electrónico y servicio al cliente. Estos chatbots son responsables de brindar respuestas rápidas a consultas e inquietudes cortas de los usuarios, de modo que la capacidad de respuesta es imperativa para impedir la deserción de usuarios. En este contexto, un TTFT rápido (una medida de la rapidez con la que el chatbot comienza a generar una respuesta) es esencial para ofrecer una experiencia de usuario positiva, mientras que un TPOT moderado que iguale o supere ligeramente la velocidad de lectura humana se considera aceptable. Las implementaciones de producción típicas de chatbots sirven a bases de usuarios muy grandes y tienen grandes tamaños de lotes, lo que agrupa múltiples solicitudes de usuarios y las envía al sistema de IA para la inferencia en una sola solicitud.

Resumen

En el otro extremo del espectro están los casos de uso de resumen de documentos, que están cobrando impulso en varias industrias como el área de la salud para resumir documentos de investigación médica, los noticieros y medios de comunicación para resumir eventos y desarrollos clave, y los proveedores de conferencias web para generar elementos de acción a partir de las reuniones por video. En estos escenarios, las secuencias de entrada son largas, pudiendo ir de unas pocas páginas a cientos; el objetivo es generar rápidamente un resumen completo, no la capacidad de respuesta instantánea. Como resultado, el sistema debe optimizarse para un TPOT rápido que exceda con creces la velocidad de lectura humana, ya que los usuarios son más tolerantes a un TTFT más largo, particularmente a longitudes de secuencia de entrada largas. Para lograr un TPOT rápido, los tamaños de lotes en estos casos tienden a ser más pequeños, lo que requiere [optimizaciones avanzadas de pila de software](#) para maximizar el rendimiento en tamaños de lotes bajos.

Respuestas a Preguntas

Los bots de respuesta a preguntas comparten muchas similitudes con los chatbots, particularmente en términos de capacidad de respuesta rápida y de manejo de consultas cortas de usuarios. Sin embargo, difieren en que se requiere que los bots de respuesta a preguntas generen respuestas a partir de una base de conocimiento o un conjunto de datos predefinido. Si bien la consulta del usuario en sí puede ser breve, la solicitud de inferencia real enviada al LLM es mucho más larga, ya que incluye datos relevantes en forma de incrustaciones extraídas de la base de conocimiento. Este workflow se conoce comúnmente como Generación Aumentada por Recuperación o RAG. En este escenario, es esencial elegir un sistema de IA y un acelerador que funcionen de manera óptima con longitudes de secuencia de entrada largas y longitudes de secuencia de salida cortas a moderadas para lograr el mejor TCO y la mejor experiencia de usuario. Además, dado que los datos de la base de conocimiento normalmente se almacenan fuera de la memoria de GPU, en una memoria de CPU mucho más grande, la implementación de sistemas con [interconexiones rápidas entre la CPU y la GPU](#) (lo que supera las velocidades de interconexión de PCIe tradicionales) puede optimizar aún más la experiencia del usuario y reducir el costo total de propiedad.

Agentes de IA

Los chatbots de IA aprovechan actualmente la IA generativa para proporcionar respuestas basadas en interacciones únicas, utilizando el procesamiento del lenguaje natural para responder a las consultas de los usuarios. La próxima evolución en la IA es la IA agéntica, que va más allá de las respuestas simples al emplear el razonamiento avanzado y la planificación iterativa para resolver problemas complejos de múltiples pasos. Este tipo de IA ingiere grandes cantidades de datos de varias fuentes, lo que le permite analizar de forma independiente desafíos, desarrollar estrategias y ejecutar tareas. Al aprender y mejorar continuamente a través de un bucle de retroalimentación, los sistemas de IA agéntica mejoran la toma de decisiones y la eficiencia operativa.

La IA agéntica necesita llamadas de funciones y la coordinación de múltiples modelos que dan como resultado la generación de tokens adicionales durante la inferencia. Para los líderes que aprovechan los agentes de IA dentro de sus organizaciones, la selección de la pila de plataformas de inferencia correcta —una que ofrezca las herramientas y los blueprints de abstracción necesarios para orquestar de manera efectiva estas interacciones— es vital para garantizar operaciones de inferencia de alto rendimiento.

Como se demostró, los diferentes casos de uso tienen requisitos distintos para las Longitudes de Secuencia de Entrada, los Tamaños de Lotes, el Tiempo hasta el Primer Token, el Tiempo por Token de Salida y la interconexión de CPU a GPU. Centrarse en una evaluación comparativa que refleje de cerca su caso de uso de producción objetivo seleccionando la instancia correcta es crucial para mantener acuerdos de nivel de servicio de usuario consistentes y para evitar que los costos de infraestructura aumenten gradualmente debido a una insuficiencia de hardware.

Estudio de Caso de Cliente: Perplexity

[Perplexity AI](#), un motor de búsqueda impulsado por IA, maneja más de 435 millones de consultas por mes, cada una de las cuales implica múltiples solicitudes de inferencia de IA. Para satisfacer la creciente demanda y, al mismo tiempo, equilibrar el costo y la experiencia del usuario, el equipo de inferencia de Perplexity adoptó las GPU NVIDIA H100 Tensor Core, Triton Inference Server y TensorRT-LLM. El equipo sirve a más de 20 modelos de IA simultáneamente, incluidos varios modelos Llama 3.1, y usa modelos de clasificación más pequeños para hacer coincidir las solicitudes de los usuarios con el modelo apropiado. Su implementación se administra en un clúster de Kubernetes, lo que garantiza que los acuerdos de nivel de servicio (SLA) se cumplan incluso cuando el tráfico sea fluctuante.

El equipo de Perplexity se centra en la optimización del desempeño y el costo a través de estrategias efectivas de programación y procesamiento por lotes. Usan Triton Inference Server para agrupar las solicitudes entrantes y para optimizar la utilización de GPU, escalando la implementación on demand. A fin de mejorar el desempeño en tareas sensibles a la latencia, el equipo evalúa y ajusta continuamente sus algoritmos de programación para minimizar la latencia entre tokens. Además, se realizan pruebas A/B para refinar las configuraciones, lo que garantiza que los modelos cumplan con los SLA requeridos, a la vez que maximizan la utilización de recursos de GPU.

Al implementar modelos internamente mediante las GPU de NVIDIA, Perplexity logra un ahorro de costos significativo. Su estrategia de implementación, que incluye [la paralelización de modelos en múltiples GPU y el uso de TensorRT-LLM](#), les permite servir modelos a costos mínimos, a la vez que mantienen SLA estrictos.

Factores de Implementación que Afectan el Desempeño de la Inferencia

En la sección anterior, examinamos las diferentes métricas de desempeño que puede medir y optimizar dentro de una solución de inferencia, y cómo estas métricas se ven influidas por el caso de uso específico. En esta sección, nos centraremos en cómo los factores de implementación y las consideraciones arquitectónicas afectan el desempeño, abarcando temas como los siguientes:

1. Consideraciones sobre la Arquitectura de Hardware
2. Tamaño del Modelo
3. Maximización de la Utilización con la Concurrencia de Modelos
4. Múltiples Modalidades en Modelos
5. Optimización del Desempeño con Técnicas de Lotes Avanzadas

El objetivo no es proporcionar una orientación detallada sobre la implementación o la arquitectura de su solución en particular, sino equiparle con el conocimiento necesario para diseñarla para un desempeño óptimo.

Consideraciones sobre la Arquitectura de Hardware

La selección de la GPU correcta es un factor crucial que afecta significativamente el desempeño. Sin embargo, confiar únicamente en las métricas de chips o instancias máximas, como las especificaciones de FLOPS clasificadas o de memoria, puede no contar la historia completa, especialmente porque el desempeño de las cargas de trabajo entregadas depende en gran medida de muchos factores, incluida la eficiencia de la pila de software. De manera similar, el precio absoluto de una GPU o su costo por hora en la nube no es una métrica significativa. Lo que realmente importa es el desempeño ofrecido por vatio por dólar gastado. Esto significa que una GPU con un costo por hora más alto que otra puede proporcionar un costo general por token menor que una con un costo por hora menor.

Los data centers y las [fábricas de IA](#) tienen una energía limitada, lo que hace que sea crítico maximizar el rendimiento de los data centers o de inferencia de las fábricas de IA dentro de un presupuesto de energía dado. El rendimiento de inferencia ofrecido para una cantidad dada de energía utilizable, es decir, [la eficiencia energética](#), es crítica para maximizar el rendimiento de inferencia de los data center y, en última instancia, el potencial de ingresos.

Arquitectura de GPU Optimizada para la Inferencia

Desde su debut en los data centers en 2012, las GPU NVIDIA han transformado la industria al permitir el procesamiento paralelo y reducir significativamente el tiempo necesario para tareas

que requieren muchos recursos. Este cambio ha llevado a mejoras drásticas, lo que ofrece hasta 30 veces más desempeño por vatio y 60 veces más desempeño por dólar en comparación con los sistemas tradicionales basados en CPU.

NVIDIA continúa superando los límites de la innovación, lo que ofrece un desempeño innovador con cada generación. La última [arquitectura NVIDIA Blackwell ofrece velocidades de inferencia 30 veces más rápidas](#) para modelos de billones de parámetros en comparación con la generación anterior. Esto es posible gracias a avances innovadores como la integración de un motor transformer de segunda generación e interconexiones NVLINK más rápidas y de mayor ancho, lo que resulta en un desempeño órdenes de magnitud mayor al de su predecesor.




Figura 3 GPU NVIDIA Blackwell Desarrollada con 208 Mil Millones de Transistores para Ofrecer un Desempeño de Inferencia Incomparable

Blackwell, desarrollada con 208 mil millones de transistores, más de 2.5 veces los transistores de su predecesora, es la GPU más grande jamás hecha. Presenta un motor transformer de segunda generación que combina núcleos Tensor Blackwell personalizados con TensorRT-LLM para acelerar la inferencia en LLM y modelos de mezcla de expertos (MoE). Los núcleos Tensor Blackwell ofrecen nuevas precisiones y formatos de microescala para una precisión y un rendimiento mejorados. Transformer Engine mejora el desempeño con el escalado de microtensores y permite FP4 AI, duplicando el desempeño, el ancho de banda de HBM y el tamaño de los modelos por GPU, en comparación con los FPS.

Emparejamiento de GPU con CPU con Eficiencia Energética

El Superchip NVIDIA GB200 Grace Blackwell conecta dos GPU NVIDIA Blackwell Tensor Core de alto desempeño y una CPU NVIDIA Grace mediante la interconexión NVIDIA® NVLink®-C2C que ofrece 900 gigabytes por segundo (GB/s) de ancho de banda bidireccional a las dos GPU.




Figura 4 El Superchip NVIDIA GB200 Incluye Dos GPU Blackwell y una CPU Grace

La CPU NVIDIA Grace combina 72 núcleos Arm Neoverse V2 de alto desempeño y eficiencia energética, conectados con la Estructura de Coherencia Escalable (SCF) de NVIDIA. NVIDIA SCF es una estructura de alto ancho de banda en el chip que proporciona un total de 3.2 TB/s de ancho de banda de bisección, el doble que las CPU tradicionales.

Grace es la primera CPU de data center en usar memoria LPDDR5X de alta velocidad con confiabilidad de clase de servidor a través de mecanismos como el código de corrección de errores (ECC). Grace ofrece hasta 500 GB/s de ancho de banda de memoria, a la vez que consume solo una quinta parte de la energía de la memoria DDR tradicional a un costo similar.

Estas numerosas innovaciones significan que NVIDIA Grace ofrece un desempeño, un ancho de banda de memoria y capacidades de movimiento de datos sobresalientes con un desempeño por vatio innovador.

Múltiples GPU Trabajan Juntas como Una durante la Inferencia

Si bien la selección de la GPU correcta es crítica para las implementaciones de IA, la computación a exaescala y los modelos de IA de billones de parámetros requieren una comunicación fluida de GPU a GPU, lo que permite a múltiples GPU trabajar en conjunto como una sola GPU masiva durante la inferencia.

NVIDIA GB200 NVL72 conecta 36 Superchips GB200 (36 CPU Grace y 72 GPU Blackwell) en un diseño a escala de bastidor. El GB200 NVL 72 es un dominio NVLink de 72 GPU a escala de bastidor refrigerado por líquido, que puede actuar como una sola GPU masiva.

NVIDIA GB200 NVL72 aprovecha NVLink de quinta generación de NVIDIA, que duplica el desempeño en comparación con la generación anterior a 100 GB/s por enlace, lo que permite una transferencia de datos más rápida y un escalado optimizado para grandes modelos de IA. También cuenta con el Switch NVLink de NVIDIA, que permite un ancho de banda de GPU de

30 TB/s en un dominio NVLink de 72 GPU (NVL 72) para el paralelismo de modelos. Cuando se combinan, NVLink y el Switch NVLink admiten clústeres de múltiples servidores con una interconexión de 1.8 TB/s, lo que escala las comunicaciones de GPU y la computación.



Figura 5 NVIDIA GB200 NVL 72

GB200 NVL 72 ofrece una aceleración de inferencia de 30 veces en comparación con la generación anterior, con un TCO 25 veces menor y 25 veces menos energía con el mismo número de GPU para modelos masivos como GPT MoE 1.8 T.




Figura 6 GB200 Ofrece un Rendimiento 30 Veces Superior en Tiempo Real en Comparación con H100

Tamaño del Modelo

Al seleccionar un LLM para la implementación de cargas de trabajo, una consideración importante es la cantidad de parámetros o el tamaño del modelo. Con el tiempo, el número de parámetros de los LLM de vanguardia ha seguido aumentando, produciendo así mejoras en las capacidades de los modelos y en su calidad de respuesta.

Para servir a un amplio conjunto de casos de uso, escenarios de implementación y presupuestos, los desarrolladores de modelos a menudo proporcionarán variantes de sus modelos en una gama de tamaños. Por ejemplo, la familia de modelos abiertos Llama 3.1 está disponible en formatos de 8000, 70 mil y 405 mil millones de parámetros. Generalmente, dentro de una familia de modelos, los modelos más grandes proporcionarán respuestas más precisas. Sin embargo, es importante tener en cuenta que los modelos más grandes también requieren más recursos computacionales para generar tokens que los más pequeños.

Esto significa que la selección del tamaño de modelos depende del caso de uso previsto y de los recursos de computación disponibles. Para los casos de uso que exigen la mayor precisión de respuesta para tareas complejas, los modelos más grandes pueden ser la opción preferida. Sin embargo, para los escenarios en los que la velocidad de generación de tokens de salida es crítica o los recursos de computación disponibles son limitados, se puede preferir el uso de un modelo más pequeño.

Maximización de la Utilización por Medio de la Concurrencia de Modelos

A medida que las GPU de data center continúan evolucionando, los recursos de computación y memoria que ofrecen están creciendo rápidamente con cada nueva generación. Estas GPU de última generación son altamente efectivas para acelerar la inferencia a escala masiva, como en el servicio a modelos de razonamiento de Combinación de Expertos. Sin embargo, esta potencia viene con una advertencia: al servir a modelos más pequeños, con frecuencia se subutilizan grandes recursos de computación y memoria, generando un Costo Total de Propiedad (TCO) más alto.

En estos escenarios, los recursos de la GPU no se utilizan de manera eficiente, ya que grandes porciones de la capacidad de computación y memoria permanecen inactivas. Esto da como resultado costos de infraestructura innecesarios, y crea un desequilibrio entre los recursos implementados y los requisitos reales de la carga de trabajo.

La concurrencia de modelos ofrece una solución elegante a este desafío. Al permitir que múltiples modelos, o múltiples instancias del mismo modelo, se ejecuten simultáneamente en una sola GPU o en todas las GPU de un nodo, el rendimiento del sistema aumenta y la latencia disminuye, todo sin requerir inversiones cada vez mayores en infraestructura. Este enfoque permite a las organizaciones maximizar el uso de sus recursos de GPU existentes, lo que garantiza la total utilización de la capacidad de cómputo y la optimización de costos de infraestructura.




Figura 7 Cómo el Aumento de la Concurrency de Modelos Afecta el Rendimiento y la Latencia

NVIDIA Dynamo-Triton agiliza el proceso de implementación de modelos con la concurrencia habilitada. Los desarrolladores pueden implementar fácilmente la concurrencia de modelos activando un solo indicador en el archivo de configuración del modelo. A partir de ahí, pueden especificar cuántas instancias de modelos simultáneos implementar y qué GPU objetivo usar. Esta simplicidad permite a los desarrolladores aprovechar todo el poder de su infraestructura de GPU sin procesos de configuración compleja ni de escalado manual.

En escenarios en los que es necesario servir a múltiples modelos independientes, pero no todos pueden caber al mismo tiempo en la misma instancia o nodo, NVIDIA Dynamo-Triton puede funcionar como un multiplexor. Carga y descarga modelos de forma dinámica en función de las solicitudes de usuario entrantes, lo que garantiza que los modelos requeridos estén disponibles en el momento adecuado. Esto permite a las organizaciones mantener una alta disponibilidad y un desempeño de servicios sin la necesidad de inversiones en infraestructura adicionales.




Figura 8 Cómo NVIDIA Dynamo-Triton Puede Cargar y Descargar Modelos en una GPU, Aumentando la Disponibilidad y el Desempeño del Servicio

Además de mejorar el rendimiento y de reducir los costos, la concurrencia de modelos también aborda situaciones en las que la demanda de un servicio por parte del usuario no es predecible de antemano. Los equipos de TI pueden comenzar con una sola instancia de un modelo y escalar gradualmente mediante la implementación de múltiples instancias simultáneas del modelo a medida que aumenta la demanda. La capacidad de ajustar el número de modelos simultáneos permite cumplir con las demandas cambiantes, a la vez que minimiza el costo de los recursos de computación no utilizados.

La concurrencia de modelos es una potente herramienta de desempeño de inferencia, particularmente cuando se implementan modelos de tamaño pequeño a mediano en las GPU de data center. Al utilizar este enfoque, las organizaciones pueden experimentar beneficios significativos:

- **Mayor rendimiento:** La ejecución de múltiples modelos o instancias de modelos en paralelo mejora el rendimiento general del sistema, lo que le permite manejar más solicitudes de inferencia simultáneamente.
- **Menor costo por token:** Al hacer uso completo de los recursos existentes, la concurrencia de modelos reduce el costo por token servido, lo que garantiza que las inversiones en infraestructura se maximicen.
- **Latencia reducida:** La ejecución simultánea de modelos o instancias de modelos reduce los tiempos de espera, lo que mejora la capacidad de respuesta del servicio y mejora la experiencia del usuario.

Múltiples Modalidades en Modelos

Los modelos de IA capaces de procesar e integrar información de múltiples modalidades de datos simultáneamente, como texto, imágenes, audio y video, se llaman modelos multimodales. A diferencia de los modelos de IA unimodales tradicionales, que trabajan con una sola modalidad de entrada, los modelos multimodales tienen requisitos de servicio de inferencia complejos que deben permitir el procesamiento de entradas y la generación de resultados en varias modalidades.




Figura 9 LLM Multimodal que Fusiona Información de Múltiples Modalidades y Optimizado para un Alto Rendimiento

La plataforma de inferencia de IA de NVIDIA proporciona compatibilidad optimizada para modelos multimodales con codificadores de entrada de alto desempeño para audio e imagen mediante la biblioteca NVIDIA TensorRT y el decodificador de texto optimizado mediante la biblioteca TensorRT-LLM. Estos modelos se pueden implementar mediante Dynamo-Triton de NVIDIA, que admite varias funciones avanzadas como la inferencia de múltiples imágenes, en la que una sola solicitud puede contener múltiples imágenes, y la reutilización de caché de KV efectiva, en la que las imágenes podrían compartirse en múltiples tokens de entrada de texto para ayudar a reducir la latencia y mejorar el desempeño proporcional a la longitud de la reutilización de caché de KV.

Optimización del Desempeño con Técnicas de Lote Avanzadas

Los aceleradores de data center, como las GPU de NVIDIA, utilizan múltiples núcleos para procesar solicitudes en paralelo. Para maximizar el potencial de estos núcleos, las solicitudes a menudo se agrupan en lotes y se envían para la inferencia. Sin embargo, existe una compensación crítica entre el tamaño del lote, el rendimiento y la latencia. El ajuste de cualquiera de estos dos factores puede afectar negativamente al tercero, lo que crea desafíos para las empresas que buscan un desempeño óptimo.

Por ejemplo, un tamaño de lote más pequeño puede reducir la latencia, pero conduce a recursos de GPU subutilizados, lo que genera ineficiencias y mayores costos operativos. Por otro lado, los

lotes más grandes maximizan el uso de los recursos de GPU, pero a costa de un aumento de la latencia, lo que puede afectar negativamente la experiencia del usuario.

Los equipos de TI a menudo realizan pruebas A/B para determinar el equilibrio ideal para su caso de uso, pero esto puede ser un proceso complejo y laborioso. El aprovechamiento de una plataforma de software de inferencia avanzada, como NVIDIA Dynamo-Triton y NVIDIA TensorRT-LLM, puede mitigar esta relación de compromiso. La plataforma de inferencia de IA de NVIDIA implementa técnicas de procesamiento por lotes sofisticadas para ayudar a las organizaciones a alcanzar un mejor equilibrio entre el rendimiento y la latencia, lo que mejora el desempeño general del sistema.

Lotes Dinámicos

El procesamiento dinámico por lotes crea lotes en función de criterios específicos como el tamaño de lote máximo o preferido y el tiempo de espera máximo. Si el lote se puede formar con el tamaño preferido, se procesará con ese tamaño; de lo contrario, el sistema formará un lote del tamaño más grande posible que cumpla con el tamaño máximo de lote configurado. Al permitir que las solicitudes permanezcan en la cola durante un corto tiempo, el procesamiento dinámico por lotes puede esperar hasta que lleguen solicitudes adicionales para crear un tamaño de lote más grande, lo que mejora el rendimiento y la utilización de recursos, reduciendo en última instancia el costo por token.



Figura 10 Cómo el Procesamiento Dinámico por Lotes Crea Lotes de Múltiples Solicitudes

Procesamiento Secuencial por Lotes

Para los casos de uso que requieren una secuenciación de solicitudes específica, como el streaming de video, el procesamiento secuencial por lotes garantiza que las solicitudes relacionadas (por ejemplo, los fotogramas en un video) se procesen en un orden significativo. Cuando las solicitudes se correlacionan, como las de una transmisión de video en la que el modelo necesita mantener el estado entre marcos, el procesamiento secuencial por lotes garantiza que las solicitudes se procesen secuencialmente en la misma instancia. Esto garantiza el resultado correcto, a la vez que optimiza el desempeño.




Figura 11 Cómo el Procesamiento Secuencial por Lotes Crea Lotes de Solicitudes Diferentes, a la Vez que Mantiene las Relaciones y las Secuencias de las Solicitudes

Procesamiento por Lotes Inflight

El procesamiento por lotes Inflight mejora el procesamiento por lotes tradicional al permitir el manejo continuo de solicitudes. Con el procesamiento por lotes Inflight, el tiempo de ejecución de TensorRT-LLM (un SDK de NVIDIA que optimiza los LLM para la inferencia) procesa las solicitudes tan pronto como están listas, sin esperar a que se complete todo el lote. Esto permite un procesamiento más rápido y un mayor rendimiento, al iniciar inmediatamente nuevas solicitudes mientras que otras aún se están procesando.

Lotes y Programación
Planificador de Lotes Iterativo

Secuencia 1	Token	Token	<EOS>		
Secuencia 2	Token	Token	Token	Token	<EOS>
Secuencia 3	<EOS>				
Secuencia 4	Token	<EOS>			
Secuencia 5	Token	Token	Token	<EOS>	

Secuencia 1	Token	Token	<EOS>	Secuencia 8	Token
Secuencia 2	Token	Token	Token	Token	<EOS>
Secuencia 3	<EOS>	Secuencia 6	Token	Token	Token
Secuencia 4	Token	<EOS>	Secuencia 7	Token	Token
Secuencia 5	Token	Token	Token	<EOS>	Secuencia 9

Figura 12 Cómo el Procesamiento por Lotes Inflight Puede Eliminar las Solicitudes Dentro de un Lote una Vez Completadas y Reemplazarlas por Otras Nuevas

El uso eficiente de los recursos de computación requiere una administración cuidadosa del tamaño de los lotes, el rendimiento y la latencia. Las técnicas avanzadas de procesamiento por lotes ofrecidas por la plataforma de inferencia de IA de NVIDIA, como el procesamiento dinámico por lotes, el procesamiento secuencial por lotes y el procesamiento por lotes Inflight, proporcionan a las organizaciones la flexibilidad que requieren para poder optimizar el desempeño, reducir los costos y mejorar la experiencia del usuario. Estas tecnologías ayudan a encontrar un equilibrio entre el rendimiento y la latencia, lo que permite a las empresas escalar soluciones impulsadas por IA de manera más efectiva.

Paralelización de la Inferencia para Grandes Modelos: Métodos y Compensaciones Clave

A medida que aumentan el tamaño y la complejidad de los [grandes modelos de lenguaje](#) (LLM), se vuelve cada vez más crucial garantizar que los mismos puedan implementarse de manera eficiente en múltiples GPU. Cuando los modelos exceden la capacidad de memoria de una sola GPU, se emplean técnicas de paralelización para dividir la carga de trabajo y optimizar el desempeño. Para los ejecutivos y los líderes de TI, la comprensión de los principales métodos de paralelismo y su impacto en el rendimiento y la interactividad del usuario es clave para tomar decisiones de infraestructura informadas. A continuación se presentan los principales métodos para paralelizar la inferencia en grandes modelos y ejemplos de los principales estudios de casos.

Paralelismo de Datos (DP)

El paralelismo de datos implica la duplicación del modelo en múltiples GPU o clústeres de GPU. Cada GPU procesa de forma independiente grupos de solicitudes de usuario, lo que garantiza que no se requiera comunicación entre estos grupos de solicitudes. Este método escala linealmente con el número de GPU usadas, lo que significa que el número de solicitudes atendidas aumenta de manera directamente proporcional a los recursos de GPU asignados. Sin embargo, es importante tener en cuenta que el paralelismo de datos por sí solo generalmente es insuficiente para los últimos LLM a gran escala, ya que los pesos de sus modelos no suelen caber en una sola GPU. En consecuencia, el DP se usa comúnmente junto con otras técnicas de paralelismo.




Figura 13 Aplicación del Paralelismo de Datos en Múltiples GPU

Impacto en el Desempeño:

- **Rendimiento de GPU:** No se ve afectado solo por el DP, ya que el modelo está duplicado.
- **Interactividad del Usuario:** No hay un impacto significativo, ya que las solicitudes se procesan de forma independiente.

Paralelismo Tensorial (TP)

En el paralelismo tensorial, los parámetros de los modelos se dividen en múltiples GPU, y las solicitudes de usuario se comparten entre dichas GPU o clústeres de GPU. Los resultados de los cálculos realizados en diferentes GPU se combinan en la red de GPU a GPU. Este método puede mejorar la interactividad del usuario, especialmente en modelos basados en transformers como Llama 405B y GPT4 1.8T MoE (modelo de mezcla de expertos de 1.8 billones de parámetros), al garantizar que cada solicitud se procese con más recursos de GPU, acelera el tiempo de procesamiento.

Impacto en el Desempeño:

- **Rendimiento de GPU:** El escalado de TP a grandes cantidades de GPU, sin una interconexión rápida como NVLink de NVIDIA, puede reducir el rendimiento debido al aumento de la sobrecarga de comunicación.
- **Interactividad del Usuario:** Mejora a medida que las solicitudes de usuario se van procesando más rápido, con más recursos de GPU asignados a cada solicitud.




Figura 14 Aplicación del Paralelismo Tensorial en una Red Neuronal Profunda

Paralelismo de Pipeline (PP)

El paralelismo de pipeline divide las capas del modelo, y cada grupo de capas se asigna a diferentes GPU. El modelo procesa las solicitudes secuencialmente a través de las GPU, y cada GPU realiza cálculos en su parte asignada del modelo. Este método es beneficioso para distribuir grandes pesos de modelos que no caben en una sola GPU, pero tiene limitaciones en términos de eficiencia.

Impacto en el Desempeño:

- **Rendimiento de GPU:** Puede resultar en una menor eficiencia a medida que se distribuyen los pesos de los modelos.
- **Interactividad del Usuario:** No permite una optimización significativa de la interactividad del usuario, ya que el procesamiento debe proceder de forma secuencial en todas las GPU.




Figura 15 Uso del Paralelismo de Pipeline en una Red Neuronal Profunda

Paralelismo de Expertos (EP)

El paralelismo de expertos implica el enrutamiento de las solicitudes de usuarios a "expertos" especializados dentro del modelo. Al limitar cada solicitud a un conjunto más pequeño de parámetros (es decir, a expertos específicos), el sistema reduce la sobrecarga de computación y optimiza el procesamiento. Las solicitudes son procesadas por expertos individuales antes de recombinarse en la etapa de salida final, lo que requiere una comunicación de GPU a GPU de alto ancho de banda.

Impacto en el Desempeño:

- **Rendimiento de GPU:** El paralelismo de expertos puede ofrecer mejoras significativas en el rendimiento, especialmente cuando se combina con otras técnicas.
- **Interactividad del Usuario:** Las configuraciones de EP pueden mantener o mejorar la interactividad del usuario sin las grandes compensaciones requeridas en otros métodos.




Figura 16 Uso del Paralelismo de Expertos en una Red Neuronal Profunda que Consta de Cuatro Expertos

Combinación de Métodos de Paralelismo para un Desempeño Óptimo

La forma más efectiva de optimizar el desempeño de los LLM en múltiples GPU es combinando múltiples técnicas de paralelismo. Al hacerlo, se hace posible minimizar la compensación entre el rendimiento y la interactividad del usuario, lo que garantiza un alto desempeño y experiencias de usuario con buena capacidad de respuesta.

Por ejemplo, cuando se sirve el modelo GPT MoE 1.8 T con 16 expertos, mediante 64 GPU, cada una con 192 GB de memoria, observamos que el Paralelismo Experto + Pipeline (EP 16PP4) ofrece una mejora de dos veces en la interactividad del usuario con una reducción insignificante en el rendimiento de la GPU en comparación con el paralelismo solo de expertos y el Paralelismo de Tensor + Experto + Pipeline (TP4EP4PP4) ofrece un rendimiento de GPU 3 veces mayor en comparación con el paralelismo solo de tensores, a la vez que mantiene el nivel de interactividad del usuario.

Para los directores de sistemas de información y los líderes de TI que supervisan la implementación de LLM, es esencial comprender las compensaciones y los beneficios de diversas estrategias de paralelización. La combinación de métodos de paralelismo como datos, tensor, pipeline y el paralelismo de expertos permite a las organizaciones optimizar la utilización

de recursos de GPU y mejorar el rendimiento y la interactividad del usuario. En la práctica, las configuraciones bien planificadas pueden ofrecer resultados óptimos, equilibrando así el alto desempeño en las experiencias de usuario con una capacidad de respuesta desde múltiples GPU. A medida que aumenta la demanda de modelos más grandes y complejos, estas técnicas de paralelización desempeñarán un papel crítico para garantizar una implementación escalable y eficiente de modelos de IA.

Habilitación del Desempeño de la Inferencia de IA y la Eficiencia de Costos en la Nube

La nube ha sido durante mucho tiempo una fuerza transformadora para las empresas, pues permite infraestructuras de TI escalables, eficientes y accesibles a nivel mundial. A medida que las empresas transfirieron cargas de trabajo como el almacenamiento, las bases de datos y la planificación de recursos empresariales a la nube en busca de flexibilidad y ahorro de costos, la inferencia de IA está siguiendo esta misma ruta. Según un informe reciente de IDC, el segmento de crecimiento más rápido para la inferencia de IA en la empresa será en las instancias de computación acelerada en la nube, y se proyecta que la adopción de este mecanismo supere a todos los demás modelos de implementación por un factor de tres.

Para los líderes de TI, este cambio presenta una oportunidad significativa para mejorar el desempeño sin aumentar los costos. Al combinar la computación acelerada basada en la nube con el software de IA optimizado, las organizaciones podrán alcanzar mayores niveles de velocidad, escalabilidad y rentabilidad. Para optimizar el desempeño de la inferencia de IA en la nube, los líderes de TI deben garantizar que sus equipos tengan flexibilidad suficiente para elegir entre una amplia gama de tipos de GPU diferentes, asignando la GPU adecuada a cada carga de trabajo específica. Esta elección estratégica es clave para aprovechar todo el potencial de la inferencia de IA en la nube, pues evita el suministro excesivo o insuficiente de los recursos de computación acelerados.

Es igualmente importante seleccionar una pila de inferencia de IA que se integre profundamente con las herramientas de nube en las que los equipos de TI ya estén entrenados y certificados. Esta integración minimiza los costos de entrenamiento y permite a los equipos centrarse en la optimización del desempeño de inferencia en lugar de tener que lidiar con tareas de integración de software complejas. Para aumentar aún más la flexibilidad y evitar la dependencia de proveedores, los líderes de TI deben priorizar las GPU y las pilas de inferencia que están disponibles en todos los principales proveedores de servicios de nube (CSP). Esto permite la implementación de GPU más cerca de los usuarios finales y brinda a los equipos de inferencia de IA la libertad de seleccionar la mejor plataforma de nube para sus necesidades específicas de aplicaciones.

Una de las ventajas sobresalientes del uso de las soluciones de computación acelerada de NVIDIA en la nube es la flexibilidad y la elección que proporciona. Diferentes generaciones de GPU de NVIDIA impulsan instancias de computación en la nube en todos los principales proveedores de servicios de nube, lo que ofrece una amplia gama de opciones para ayudar a las empresas y a los desarrolladores a elegir las soluciones de computación acelerada que mejor satisfagan sus necesidades.



Figura 17 Amplia Compatibilidad con la Plataforma de Inferencia de NVIDIA en la Nube

Además, la pila de Inferencia de IA de NVIDIA está completamente integrada con todas las principales herramientas de MLOps de nube, lo que simplifica la implementación y el escalado de las cargas de trabajo de IA. Por ejemplo, NVIDIA Dynamo-Triton y NVIDIA NIM están integrados con todas las principales herramientas de IA en la nube, lo que permite a los equipos de TI implementar modelos con un esfuerzo mínimo. Ya sea que usen AWS SageMaker, Google Vertex AI, Azure ML o la Nube de Ciencia de Datos de OCI, las empresas pueden lanzar NVIDIA Dynamo-Triton y NVIDIA NIM con opciones de bajo código o sin código, ahorrando así tiempo y recursos de TI.

Para las organizaciones que buscan un enfoque más optimizado, NVIDIA también ofrece Imágenes de Máquinas de Nube preconfiguradas con todos los drivers y dependencias necesarios preinstalados. Esto permite la implementación rápida de cargas de trabajo de IA sin configuración manual, lo que permite a las empresas ahorrar tiempo y costos en la configuración.

Al aprovechar la computación acelerada de NVIDIA y las soluciones de inferencia de IA integradas, los líderes de TI pueden garantizar que su desempeño de inferencia de IA escale de manera efectiva en la nube, con flexibilidad, rentabilidad y un gasto general mínimo.

Estudio de Caso de Cliente: Amdocs

Amdocs, un proveedor líder de software y servicios para los proveedores de comunicaciones y medios, desarrolló amAlz: una plataforma de IA generativa específica para las telecomunicaciones adaptada para la industria de las telecomunicaciones. Para mejorar el desempeño y acelerar la implementación, Amdocs usó los microservicios de inferencia NVIDIA NIM en NVIDIA OGX Cloud para la implementación fluida de LLM ajustados para la atención al cliente y las consultas de ventas en tiempo real.

Amdocs seleccionó un conjunto de datos anotados por humanos a partir de transcripciones de llamadas anónimas, interacciones con clientes y facturas utilizadas para técnicas de ajuste fino de parámetros eficientes, como la Adaptación de Bajo Rango (LoRA), de LLM como la familia de modelos Llama de Meta y Mixtral 8x7B de Mistral AI. El equipo automatizó la implementación de modelos ajustados con NIM y logró una latencia reducida en un 80 %, lo que permite respuestas casi en tiempo real, así como mejoras de precisión del 30 %. La personalización de dominios a través del ajuste fino también redujo el consumo de tokens en un 40 %, lo que reduce los costos de infraestructura.

Con NVIDIA NIM en OGX Cloud, Amdocs mejoró significativamente la precisión y los tiempos de respuesta de LLM, a la vez que redujo los costos, lo que permite a la plataforma amAlz cumplir con las demandas de las aplicaciones de telecomunicaciones modernas.

Escalado de la Inferencia de IA para Satisfacer la Demanda Fluctuante

Al implementar aplicaciones de IA, uno de los mayores desafíos que enfrentan los líderes de TI es la previsión de la demanda de los usuarios y la comprensión de cómo esa demanda fluctuará con el tiempo. Estos pronósticos influyen significativamente en las decisiones de infraestructura, particularmente en relación a suministros como las GPU, que afectan directamente el costo y el desempeño. El equilibrio de estos elementos es clave para garantizar que los sistemas de IA puedan escalar de forma dinámica, sin exceder los costos.

Las aplicaciones de IA, y en particular aquellas que aprovechan LLM optimizados, requieren una potencia computacional sustancial para la inferencia en tiempo real. Un enfoque común para escalar estas aplicaciones implica suministrar GPU en función de la demanda máxima proyectada. Sin embargo, esto puede ser ineficiente, especialmente cuando la demanda máxima es solo temporal o irregular.

Para abordar esto, las organizaciones necesitan la flexibilidad necesaria para escalar la infraestructura hacia arriba o hacia abajo, en respuesta a las demandas fluctuantes. Kubernetes proporciona una solución ideal, lo que permite a los equipos de TI escalar dinámicamente la implementación de los LLM. Ya sea escalando de una sola GPU a múltiples GPU o reduciendo los recursos durante las horas no pico, Kubernetes ofrece un enfoque rentable y optimizado para la administración de infraestructura.

Flexibilidad con Kubernetes y la Plataforma de Inferencia de IA de NVIDIA

Particularmente en industrias como el comercio electrónico o el servicio al cliente, las empresas enfrentan constantemente volúmenes fluctuantes de solicitudes de inferencia. Ya sea que se trate de manejar altos volúmenes de consultas de clientes durante una venta o de administrar menos solicitudes durante las horas nocturnas, la capacidad de escalar de manera eficiente es fundamental. El escalado con Kubernetes permite a las organizaciones ajustar dinámicamente

la cantidad de GPU necesarias, lo que garantiza que los recursos de hardware se alineen con la demanda en tiempo real. Este enfoque ofrece ahorros sustanciales en comparación con el sobreaprovisionamiento de recursos de hardware para manejar cargas de trabajo máximas.

La plataforma de inferencia de IA de NVIDIA, incluidos NVIDIA Dynamo-Triton, así como NVIDIA NIM, admite Kubernetes para facilitar el proceso de escalado. A medida que aumentan las solicitudes de inferencia, las métricas de Triton son extraídas por Prometheus y enviadas a Kubernetes Horizontal Pod Autoscaler (HPA), lo que agrega más pods a la implementación, cada uno con una o más GPU. Un ejemplo de una métrica personalizada que se puede extraer de NVIDIA Dynamo-Triton mediante Prometheus y enviar a la HPA de Kubernetes para informar las decisiones de escalado es la *relación entre la cola y la computación*. Esta relación refleja el tiempo de respuesta de las solicitudes de inferencia. Se define como el tiempo de cola dividido por el tiempo de computación necesario para una solicitud de inferencia.




Figura 18 Escalado de Servidores NVIDIA Triton con la Arquitectura de Kubernetes

Beneficios clave de las implementaciones de IA escalables:

1. **Eficiencia de Costos:** El escalado on demand permite a las empresas optimizar sus costos de infraestructura, garantizando que tengan solo el hardware necesario para manejar las solicitudes en tiempo real. Esta escalabilidad dinámica reduce la necesidad de sobreaprovisionamiento, que puede ser costoso.
2. **Optimización del Desempeño:** Al equilibrar los recursos de GPU de forma dinámica, Kubernetes y NVIDIA Triton garantizan que el desempeño siga siendo alto, incluso durante períodos de carga pesada. Esto permite a las aplicaciones de IA cumplir con estrictos requisitos de latencia y precisión que son esenciales en los entornos orientados al cliente.
3. **Flexibilidad en Todas las Industrias:** Desde el manejo del aumento del tráfico durante eventos de compra en línea hasta la administración de volúmenes de solicitudes fluctuantes en los centros de llamadas, la implementación escalable de IA ofrece una flexibilidad que puede adaptarse a las necesidades de una amplia gama de industrias.

Para obtener más detalles sobre la optimización de las implementaciones de IA con NVIDIA Dynamo-Triton y Kubernetes, visite [Escalado de LLM con NVIDIA Dynamo-Triton y NVIDIA TensorRT-LLM Usando Kubernetes](#). Para obtener más detalles sobre la optimización de las implementaciones de IA con NVIDIA NIM y Kubernetes, visite [Escalado Automático de NVIDIA NIM en Kubernetes](#) y [Administración de Pipelines de Inferencia de IA en Kubernetes con NVIDIA NIM Operator](#).

Optimización de los Pipelines de IA con Conjuntos de Modelos

Los sistemas de IA y machine learning (o ML) rara vez se implementan como modelos independientes. Más bien, a menudo son parte de un pipeline más amplio y complejo que integra varios modelos, pasos de preprocesamiento y tareas de posprocesamiento. Este enfoque, conocido como Conjuntos de Modelos, se ha convertido en una piedra angular de los workflows de IA modernos, especialmente en aplicaciones empresariales.

Un Conjunto de Modelos se refiere a la integración de múltiples modelos de machine learning, pasos de preprocesamiento y posprocesamiento en un pipeline unificado. En lugar de ejecutar modelos de forma individual, los conjuntos permiten a estos componentes trabajar en conjunto, lo que agiliza el proceso y mejora la eficiencia general. Cada modelo del conjunto normalmente maneja un aspecto diferente de la tarea, ya sea el procesamiento de datos, la generación de predicciones o el refinamiento de resultados.

En escenarios prácticos, como en las aplicaciones empresariales, un pipeline de IA puede incluir múltiples modelos de visión por computadora, editores de imágenes y otros modelos especializados, todos trabajando juntos para producir un resultado final. Por ejemplo, al crear una campaña de marketing usando SDXL (un modelo de IA generativa), el workflow puede requerir un paso de preprocesamiento inicial de zoom, seguido de la generación de una escena usando SDXL y finalizar con un paso de posprocesamiento, como el aumento de escala de la imagen para la visualización de alta resolución.

Al unir estos pasos individuales en un pipeline cohesivo, las empresas pueden garantizar un óptimo flujo de datos a través de los modelos, reduciendo al mismo tiempo la latencia y optimizando el uso de recursos.

El Papel de NVIDIA Dynamo-Triton en los Conjuntos de Modelos

El desarrollo y la administración de estos pipelines de modelos complejos pueden ser desafiantes. Sin embargo, ciertas herramientas de la plataforma de inferencia de IA de NVIDIA, como NVIDIA Dynamo-Triton, ofrecen soluciones potentes para automatizar el proceso, brindando capacidades avanzadas para orquestar conjuntos de modelos.

La función Conjuntos de Modelos de Dynamo-Triton elimina la necesidad de escribir código manual para administrar cada paso, reduciendo así la complejidad y minimizando el riesgo de errores. Además, Dynamo-Triton admite la ejecución de preprocesamiento y posprocesamiento en CPU, mientras que el modelo de IA central puede ejecutarse en GPU, lo que proporciona flexibilidad para equilibrar la potencia de procesamiento. Además, Dynamo-Triton admite la adición de funciones avanzadas al conjunto, como la lógica condicional y los bucles, lo que permite a los desarrolladores crear workflows de IA más sofisticados y flexibles.

Beneficios de los Conjuntos de Modelos con Triton

El uso de Conjuntos de Modelos viene con varios beneficios clave, especialmente cuando se integra con Dynamo-Triton:

1. **Latencia Reducida:** Al combinar el preprocesamiento, la inferencia y el posprocesamiento en un solo pipeline, las empresas pueden reducir significativamente el tiempo dedicado a mover datos entre modelos. Esta reducción de la latencia es crucial para las aplicaciones de IA en tiempo real, como la IA generativa y la visión por computadora.
2. **Utilización Mejorada de Recursos:** Los conjuntos de modelos permiten a los equipos optimizar la implementación de recursos. Por ejemplo, al ejecutar tareas de preprocesamiento y posprocesamiento más livianas en las CPU y reservar recursos de GPU para tareas de modelos más intensivas, las empresas pueden garantizar un escalado rentable sin sacrificar el desempeño.
3. **Menor Gasto General de Red:** Tradicionalmente, cada modelo de un pipeline de machine learning necesitaría comunicarse con otros a través de la red, transfiriendo datos intermedios entre los pasos. Sin embargo, con los Conjuntos de Modelos, estas transferencias de datos intermedias se minimizan, lo que reduce el número de llamadas de red y optimiza el uso del ancho de banda.
4. **Integración sin Código:** La función Conjuntos de Modelos de Dynamo-Triton ofrece un enfoque de bajo código o sin código para conectar diferentes modelos de IA. Esto facilita a los líderes de TI y a los equipos de inferencia la integración de workflows de preprocesamiento y posprocesamiento (a menudo desarrollados con Python) en un Pipeline fluido. Esta integración optimizada permite que una sola solicitud de inferencia active todo el proceso, lo que mejora aún más la eficiencia.

Ejemplo Práctico: Aplicaciones Generativas Impulsadas por IA

Para comprender mejor cómo funcionan los Conjuntos de Modelos, consideremos un ejemplo de IA generativa. Imagine una aplicación de texto a imagen en la que un texto de entrada se convierte en una imagen sintetizada. El pipeline para una aplicación de este tipo normalmente consiste en dos componentes principales: un LLM para codificar el texto de entrada y un modelo de difusión para generar la imagen.

Antes de que el texto de entrada se envíe al LLM, se necesita algo de preprocesamiento. Esto podría implicar la limpieza del texto, su tokenización o su formateo de una manera que sea compatible con el LLM. De manera similar, la imagen de salida puede requerir un posprocesamiento, como el cambio de tamaño o la adición de efectos, antes de que se pueda usar en la aplicación final.

El uso de Conjuntos de Modelos en este caso permitiría que el proceso de texto a imagen estuviera completamente automatizado y optimizado. Triton podría conectar de forma fluida cada paso, desde el preprocesamiento de texto hasta la generación de imágenes, e incluso manejar el posprocesamiento, todo dentro de un pipeline unificado.

El Poder de los Conjuntos de Modelos para la Optimización de la IA

Al integrar múltiples modelos y pasos de preprocesamiento y posprocesamiento en un solo pipeline optimizado, los líderes de TI pueden mejorar la eficiencia de sus aplicaciones de AI, reducir la latencia y minimizar el uso de recursos.

La plataforma de inferencia de IA de NVIDIA proporciona una plataforma potente para administrar estos conjuntos, brindando flexibilidad en la asignación de recursos y simplificando la integración de diferentes componentes. Con su enfoque de bajo código y su optimización automatizada, permite a los equipos desarrollar y escalar sistemas de AI con mayor facilidad, lo que la convierte en una herramienta esencial para las empresas que buscan aumentar el desempeño de sus modelos de AI.

Estudio de Caso: Let's Enhance Convierte Fotos de Productos en Hermosos Recursos de Marketing

Un buen ejemplo de una empresa que aprovecha el poder de la plataforma de inferencia de IA de NVIDIA para servir a SDXL en los entornos de producción es [Let's Enhance](#). Esta Startup de IA pionera lleva más de tres años usando el Triton Inference Server para implementar más de 30 modelos de IA en las GPU NVIDIA Tensor Core.

Recientemente, Let's Enhance celebró el lanzamiento de su último producto, AI Photoshoot, que usa el modelo SDXL para transformar fotos de productos simples en hermosos recursos visuales para sitios web de comercio electrónico y campañas de marketing.

Con la sólida compatibilidad de Triton Inference Server para varios frameworks y backends, junto con su conjunto de funciones de procesamiento dinámico por lotes, Vlad Pranskevichus, fundador y director de tecnología de Let's Enhance, pudo integrar de forma fluida el modelo SDXL en los pipelines de IA existentes con una participación mínima de los equipos de ingeniería de ML, dejándole más tiempo para sus esfuerzos de investigación y desarrollo.

A través de una prueba de concepto exitosa, esta startup de mejora de imágenes de IA identificó una reducción del 30 % en los costos al migrar sus modelos SDXL a las GPU NVIDIA L4 en las instancias de Google Cloud G2, y ha delineado una hoja de ruta para completar la migración de varios pipelines para mediados de 2024.

Técnicas de Inferencia Avanzadas para Impulsar el Desempeño

En el capítulo anterior, cubrimos las estrategias fundamentales para aumentar el desempeño de la inferencia. En este capítulo, nos sumergimos en técnicas más avanzadas adaptadas para líderes de TI, particularmente aquellos para quienes la inferencia de IA es integral a la estrategia de generación de ingresos de su organización, o aquellos que ya han optimizado sus sistemas y ahora están buscando alcanzar el siguiente nivel de desempeño de sus inversiones en IA. Nuestro objetivo es proporcionar una Descripción General de las técnicas de optimización de vanguardia que aparecen en la plataforma de inferencia de IA de NVIDIA, guiando a los líderes para que entiendan cuál es la mejor forma de dirigir a sus equipos para que aprendan más. Exploraremos estrategias avanzadas de NVIDIA Dynamo y TensorRT-LLM, como el Prellenado en Fragmentos, la Atención de Multibloques, la Reutilización Temprana de Caché de KV, el Servicio Desagregado y la Decodificación Especulativa, cada una diseñada para superar los límites de la inferencia de IA en entornos de producción.

Prellenado en Fragmentos: Maximización de la Utilización de GPU y Reducción de la Latencia

La inferencia de LLM normalmente implica dos fases clave: el prellenado y la decodificación. En la fase de prellenado, el sistema computa la comprensión contextual de la entrada del usuario (caché de KV), que es intensiva en términos de computación. A continuación viene la fase de decodificación, generando tokens de forma secuencial, con el primer token derivado de la caché de KV. Sin embargo, los métodos tradicionales a menudo luchan para equilibrar la pesada demanda de computación de la fase de precargado y la carga más ligera de la fase de decodificación.

El Prellenado por Fragmentos es una optimización que divide la fase de prellenado en fragmentos más pequeños, lo que mejora la paralelización con la fase de decodificación y reduce los cuellos de botella. Este enfoque ayuda a manejar contextos más largos y niveles de concurrencia más altos, a la vez que maximiza la memoria de GPU y los recursos de computación. También ofrece flexibilidad al disociar el uso de memoria de la longitud de la secuencia de entrada, lo que facilita el procesamiento de grandes solicitudes sin afectar la capacidad de memoria. Con el dimensionamiento dinámico de fragmentos, TensorRT-LLM ajusta de forma inteligente los tamaños de los fragmentos en función de la utilización de la GPU, lo que simplifica la implementación y elimina la necesidad de la configuración manual.

Atención de Multibloques: Aumento del Rendimiento con Contextos Largos

Con la evolución de los modelos de IA, el tamaño de las ventanas contextuales (que permite una mejor comprensión cognitiva) ha crecido exponencialmente. Llama 2 comenzó con 4 mil tokens, y la reciente Llama 3.1 expandió esto a un impresionante número de 128 mil tokens. El manejo de estas secuencias largas en escenarios de inferencia en tiempo real presenta desafíos únicos, particularmente con la asignación de recursos de GPU.

La técnica de Atención de Multibloques dentro de TensorRT-LLM aborda estos desafíos distribuyendo eficientemente el proceso de decodificación en todos los Multiprocesadores de Streaming (SM) de una GPU. Al hacerlo, aumenta significativamente el rendimiento y reduce los cuellos de botella asociados con grandes tamaños de caché de KV. Este método garantiza que, incluso con los tamaños de lotes pequeños comunes en las aplicaciones en tiempo real, las GPU se utilicen completamente, lo que lleva a hasta 3.5 veces más tokens por segundo en la plataforma HGX H200 de NVIDIA. Este aumento del desempeño no se produce a costa del tiempo hasta el primer token (TTFT), lo que garantiza respuestas rápidas incluso para consultas complejas.

Reutilización Temprana de Caché de KV: Reducción del Tiempo al Primer Token

La generación de caché de KV es un proceso de computación intensiva. Como tal, la reutilización del caché de KV juega un papel crítico en la aceleración de la generación de tokens, pues evita computaciones redundantes. Sin embargo, los métodos tradicionales a menudo requieren esperar a que se genere toda la caché de KV antes de que pueda ocurrir la reutilización, lo que genera ineficiencias en entornos de alta demanda.


La Reutilización Temprana de Caché de KV optimiza este proceso al permitir que partes de la caché se reutilicen a medida que se generan, en lugar de esperar a que se completen. Esta técnica acelera significativamente la inferencia, especialmente en escenarios en los que se requieren indicaciones del sistema o instrucciones predefinidas. Por ejemplo, en los chatbots empresariales, donde las solicitudes de los usuarios a menudo comparten el mismo prompt del sistema, esta función puede acelerar el TTFT hasta en 5 veces durante períodos de alta demanda, brindando una experiencia de usuario más rápida y con mayor capacidad de respuesta.

Servicio Desagregado: Recursos Independientes y Escalado Desacoplado

Las configuraciones de inferencia tradicionales a menudo localizan las fases de prellenado y de decodificación en la misma GPU, lo que conduce a una asignación de recursos ineficiente y a un rendimiento subóptimo. El Servicio Desagregado de [NVIDIA Dynamo](#) separa estas fases, permitiendo

a los equipos de inferencia de IA asignar recursos de forma independiente en función de las necesidades específicas de cada fase. Esto permite un abastecimiento de recursos independiente y un escalado desacoplado, lo que significa que se pueden asignar más GPU a la fase de prellenado para optimizar el TTFT, y dedicar GPU adicionales a la fase de decodificación para mejorar el Tiempo entre Tokens (TBT).

Esta separación también introduce el paralelismo específico de la fase, donde las tareas con uso intensivo de computación en la fase de prellenado pueden beneficiarse de técnicas como el Paralelismo de Pipeline, mientras que la fase de decodificación puede aprovechar el Paralelismo de Tensores y el Paralelismo de Expertos. NVIDIA Dynamo reduce los costos de inferencia, manteniendo al mismo tiempo los Objetivos de Nivel de Servicio (SLO) para el rendimiento, el TTFT y el TBT.



Decodificación Especulativa: Aceleración de la Generación de Tokens

El proceso de generación de tokens de manera autorregresiva (uno a la vez) puede ser lento e ineficiente. La Decodificación Especulativa optimiza esto al generar múltiples secuencias de tokens potenciales en paralelo, lo que reduce el tiempo necesario para la generación de tokens. TensorRT-LLM integra varios métodos de decodificación especulativa, como Draft Target y la Decodificación Eagle, que permiten al sistema predecir múltiples tokens y seleccionar el más apropiado.

Para modelos como Llama 3.3 70B, la decodificación especulativa conduce a un aumento significativo de 3.5 veces en los tokens por segundo, lo que mejora el rendimiento y la experiencia del usuario sin comprometer la calidad del resultado. Esta técnica es particularmente beneficiosa en entornos de baja latencia y alto rendimiento, donde es esencial maximizar la eficiencia de cada paso de computación.

Enrutamiento Sensible al Contexto: Evitar la Recomputación de Caché de KV

La reutilización de la caché de KV evita la necesidad de recalcularla desde cero, lo que reduce el tiempo de inferencia y los recursos de computación. Esto es particularmente ventajoso en los casos de uso en que se ejecuta con frecuencia una misma solicitud, como las indicaciones del sistema, las interacciones de chatbots de múltiples turnos para un solo usuario y los workflows de agentes. NVIDIA Dynamo rastrea la caché de KV en grandes flotas de GPU en múltiples nodos y en implementaciones desagregadas, y enruta de manera eficiente las solicitudes entrantes, lo que minimiza la necesidad de su costosa recomputación.

Cuando llegan nuevas solicitudes de inferencia, NVIDIA Dynamo calcula una puntuación de superposición entre las solicitudes entrantes y los bloques de caché de KV ya activos en toda la memoria de todas las GPU en el clúster distribuido. Al tener en cuenta la puntuación de superposición y la distribución de la carga de trabajo en toda la flota de GPU, enruta de forma inteligente las solicitudes a los trabajadores más adecuados, lo que minimiza la recomputación de caché de KV, a la vez que garantiza una carga equilibrada en todo el clúster.

Al reducir la recomputación innecesaria de la caché de KV, NVIDIA Dynamo libera recursos de GPU. Esto permite a los proveedores de servicios de IA responder a más solicitudes de usuarios, maximizando el retorno de sus inversiones en computación acelerada.

Liberar el Futuro de la Inferencia de IA

La plataforma de inferencia de IA de NVIDIA está desarrollada para apoyar a las organizaciones en cualquier etapa de su proceso de inferencia de IA. Para aquellos que aún se encuentran en la fase de experimentación o se centran en un tiempo de lanzamiento al mercado más rápido, las estrategias descritas en el capítulo [Factores de Implementación que Afectan la Implementación de Inferencia](#) ofrecen un excelente punto de partida. Sin embargo, para las organizaciones en las que la inferencia de IA representa un importante driver de costos que afecta los márgenes brutos, el desempeño avanzado y las técnicas de ahorro de costos cubiertas en el capítulo [Liberar el Desempeño de la Inferencia de IA y la Eficiencia de Costos en la Nube](#) ayudarán a maximizar la eficiencia y el desempeño del sistema y a minimizar los costos.

Primeros Pasos con la Plataforma de Inferencia de IA de NVIDIA

La plataforma de inferencia de NVIDIA AI ofrece opciones de implementación flexibles para la inferencia a fin de cumplir con una amplia gama de requisitos empresariales y de TI.

Las empresas que buscan el tiempo de generación de valor más rápido pueden aprovechar NVIDIA NIM, que ofrece microservicios de inferencia preempaquetados y optimizados para ejecutar los últimos modelos fundacionales de IA en la infraestructura acelerada de NVIDIA en cualquier lugar.

Para una máxima flexibilidad, capacidad de configuración y extensibilidad para satisfacer sus necesidades únicas de inferencia de IA, NVIDIA ofrece NVIDIA Triton Inference Server y NVIDIA TensorRT, que proporcionan la capacidad de personalizar y optimizar su plataforma de servicio de inferencia para sus requisitos específicos.

Visite [NVIDIA AI Inference Solutions](#) para obtener más información y comenzar.